

國立虎尾科技大學

財務金融系碩士班

碩 士 論 文

結合粒子群優化算法與長短期記憶網絡的比特幣價格預測模型研究

An Investigation into Bitcoin Price Prediction Using a
Combined Particle Swarm Optimization and Long
Short-Term Memory Network Model

研 究 生：張皓彥

指導教授：涂光億

中 華 民 國 113 年 6 月

結合粒子群優化算法與長短期記憶網絡的比特幣價格預測模型研究

An Investigation into Bitcoin Price Prediction Using a Combined Particle Swarm Optimization and Long Short-Term Memory Network Model

研 究 生：張皓彥

Student：HAO-YEN CHANG

指導教授：涂光億

Advisor：GUANG-YI TU

國立虎尾科技大學

財務金融系碩士班

碩士論文

A Thesis Submitted to Department of Finance
College of Management
National Formosa University
in Partial Fulfillment of the Requirements
for the Degree of Master of Science
in
Finance

June, 2024

Huwei, Yunlin, Taiwan (R.O.C.)

中 華 民 國 113 年 6 月

國立虎尾科技大學研究所碩士班
論文口試委員審定書

財務金融系碩士班

張皓彥 君

論文題目：結合粒子群優化算法與長短期記憶網絡的比特幣價格預測模型研究

合於碩士資格水準，業經本委員會評審認可。

論文考試委員：

古東明

林慧萊

涂光億

指導教授：

涂光億

系主任：

賴雅雯

中華民國113年6月13日

結合粒子群優化算法與長短期記憶網絡的比特幣價格預測模型研究

學生：張皓彥

指導教授：涂光億

國立虎尾科技大學財務金融系碩士班

摘要

隨著全球金融市場中比特幣及其它加密貨幣快速興起，精確預測其價格變動成為金融科技領域的一項重要挑戰。本論文旨在探討一種結合粒子群優化（PSO）算法加上長短期記憶網絡（LSTM）創新模型——PSO-LSTM 模型在比特幣價格預測上的應用潛力和有效性。

本論文使用於 2015 年 1 月 1 日開始至 2024 年 5 月 1 日比特幣市場數據對 PSO-LSTM 模型進行了價格的預測，並與傳統的 LSTM 模型進行了對比。本文發現 PSO-LSTM 模型在預測準確度方面均優於傳統模型，特別是在處理市場極端條件下的預測任務時顯示出其強大的適應性和可靠性。研究還探討了比特幣模型數據預測中的潛在應用，展示了其廣泛的應用前景。

關鍵詞：比特幣，價格預測，粒子群優化（PSO），長短期記憶網絡（LSTM），PSO-LSTM 模型，機器學習，金融科技

An Investigation into Bitcoin Price Prediction Using a Combined Particle Swarm Optimization and Long Short-Term Memory Network Model

Student :HAO-YEN CHANG

Advisors : GUANG-YI TU

Department of Finance
National Formosa University

Abstract

With the rapid rise of Bitcoin and other cryptocurrencies in the global financial market, accurately predicting their price fluctuations has become an important challenge in the field of financial technology. This paper aims to explore the application potential and effectiveness of a novel model combining Particle Swarm Optimization (PSO) algorithm with Long Short-Term Memory (LSTM) network—the PSO-LSTM model—in predicting Bitcoin prices.

Using Bitcoin market data from January 1, 2015, to May 1, 2024, this paper predicts prices using the PSO-LSTM model and compares it with the traditional LSTM model. The study finds that the PSO-LSTM model outperforms the traditional model in terms of prediction accuracy, especially demonstrating its strong adaptability and reliability in handling prediction tasks under extreme market conditions. The research also discusses the potential applications in Bitcoin price data prediction, showcasing its extensive prospects.

Keywords:Bitcoin, Price Prediction, Particle Swarm Optimization (PSO), Long Short-Term Memory Network (LSTM), PSO-LSTM Model, Machine Learning, Fintech

誌謝

本論文得以完成，我要衷心感謝我的指導教授涂光億教授，是他的協助使得這份論文能夠順利完成。在整個研究過程中，涂教授不僅提供了專業的學術指導，更是在研究遭遇困難時給予我巨大的支持和鼓勵。涂教授對學術研究的嚴謹態度及對學生的關懷精神，對我影響深遠。

特別感謝實驗室的所有成員，包括我的同學游鎧源、李映蓁、陳柏安。他們在研究過程中提供了許多寶貴的意見和幫助，實驗室的合作氛圍使我受益良多。大家共同探討學術問題的時光，將是我永生難忘的寶貴記憶。

此外，我必須向我的家人表達最深的感謝。他們對我的學業和生活給予了無條件的支持和愛護，是他們的支持使我有勇氣面對各種挑戰，無論遇到多大的困難都未曾放棄。在我攻讀碩士學位的道路上，家人的鼓勵與支持是我堅持下去的最大動力。

最後，感謝所有關心和支持我的朋友及親人，你們的支持激勵了我，使我有持續前進的動力。我將這份學位的榮耀，獻給所有幫助過我、支持過我的人。謝謝大家。

目錄

中文摘要	i
英文摘要	ii
誌謝	iii
目錄	iv
表目錄	vi
圖目錄	vii
符號說明	viii
第一章 緒論	1
1.1 研究的動機與目的	1
1.1.1 研究的具體目標	1
1.1.2 研究的方向	1
1.2 研究背景	2
1.2.1 預測比特幣價格的難度與必要性	2
1.2.2 比特幣價格預測的重要性與挑戰	2
1.2.3 傳統模型應用在比特幣價格預測的挑戰	3
1.2.4 為什麼要導入 PSO-LSTM 模型	3
1.2.5 PSO-LSTM 模型的重要性與創新	3
1.2.6 PSO-LSTM 模型的實證分析	3
1.2.7 PSO-LSTM 模型的研究意義	3
1.2.8 LSTM 網絡簡介與工作原理	4
1.2.9 LSTM 在比特幣價格預測中的應用	4
1.2.10 圖解 LSTM 網絡結構	5
1.2.11 LSTM 在比特幣價格預測中的應用	6
1.2.12 PSO 算法介紹與工作原理	6
1.2.13 PSO 算法圖解	7
1.2.14 PSO 在 LSTM 模型優化中的應用	9
第二章 文獻探討	10
2.1 文獻回顧	10
2.2 文獻模型探討	11
第三章 研究流程	16
3.1 LSTM 與 PSO 的結合	16
3.2 PSO 初始化的重要性	16
3.3 模型訓練與評估的循環過程	16
第四章 研究方法與結果	19
4.1 研究方法概述	19
4.2 數據收集及預處理	19

4.3 LSTM 模型建立 -----	19
4.4 粒子群優化 (PSO) 算法運用 -----	19
4.5 實驗結果分析與評估 -----	20
4.6 程式碼概述 -----	24
4.7 比較其他預測模型 -----	25
4.8 透過程式碼找到最佳序列長度 (seq_length) 和最佳神經元數量 (neurons)----	25
第五章 結論 -----	27
參考文獻 -----	28
英文論文大綱 -----	30

國立虎尾科技大學



National Formosa University

表目錄

表 4.1	LSTM 模型並使用粒子群優化 (PSO) 算法回測比特幣 2015~2024 年 4 月價格 預測模型結果說明	22
表 4.2	LSTM 模型並使用粒子群優化 (PSO) 算法回測比特幣 2019 年 5 月到 2020 年 3 月價格預測模型結果說明	23
表 4.3	LSTM 模型並使用粒子群優化 (PSO) 算法回測比特幣 2022 年 12 月到 2023 年 9 月價格預測模型結果說明	23
表 4.4	LSTM 模型並使用粒子群優化 (PSO) 算法回測比特幣 2024 年 3 月到 2024 年 4 月價格預測模型結果說明	24

國立虎尾科技大學



National Formosa University

圖目錄

圖 1.1	LSTM 串聯組成結構。(註 1)	4
圖 1.2	LSTM 單元組成詳解。(註 2)	5
圖 1.3	PSO 粒子群算法流程圖。(註 3)	7
圖 1.4	PSO 粒子群算法流程圖。(註 3)	8
圖 2.1	參考論文採用比特幣回歸預測模型。(註 5)	11
圖 2.2	參考論文採用比特幣 DNN 預測模型使用了主要特徵的對數值、順序分區和第一次基於值的歸一化。(註 6)	12
圖 2.3	參考論文採用比特幣 LSTM 預測模型。(註 7)	13
圖 2.4	參考論文採用比特幣 Bi-LSTM 預測模型。(註 8)	14
圖 2.5	參考論文採用比特幣 GRU 預測模型。(註 9)	15
圖 4.1	LSTM 模型並使用粒子群優化 (PSO) 算法回測比特幣 2015~2024 年 4 月價格預測模型結果。	21
圖 4.2	LSTM 模型並使用粒子群優化 (PSO) 算法回測比特幣 2019 年 5 月到 2020 年 3 月價格預測模型結果。	22
圖 4.3	LSTM 模型並使用粒子群優化 (PSO) 算法回測比特幣 2022 年 12 月到 2023 年 09 月價格預測模型結果。	23
圖 4.4	LSTM 模型並使用粒子群優化 (PSO) 算法回測比特幣 2024 年 3 月到 2024 年 4 月價格預測模型結果。	24

符號說明

f_t	: 表明遺忘門裡激活向量
σ	: 表明 sigmoid 函數
W_f	: 表明遺忘門之權重
h_{t-1}	: 表明前一個時間步輸出
x_t	: 表明現在時間步輸入
b_f	: 表明遺忘門偏置項
o_t	: 表明輸出門的激活向量
h_t	: 表明當前時間步輸出
C_t	: 表明現在時間步裡細胞狀態
W_o	: 表明輸出門權重
b_o	: 表明偏置項
x_i	: 每個粒子的位置
D	: 問題的維度
w	: 表示慣性權重
$c_1 \& c_2$: 表示學習係數
$r_1 \& r_2$: 表示隨機數
p_i	: 粒子個人最佳位置
g	: 全局最佳位置

第一章 緒論

1.1 研究的動機與目的

在探索 PSO-LSTM 模型對比特幣價格預測的應用潛力與有效性的過程中，本研究的動機與目的不僅是技術性的，也涉及對當前金融市場模型預測能力的深度批判與反思。隨著比特幣等加密貨幣成為全球金融市場不可忽視的組成部分，傳統金融模型在處理這些新興資產時的局限性愈發顯著。比特幣價格的極端波動性與非線性特徵，要求我們開發更為先進、能夠捕捉這些特性的預測工具。

PSO-LSTM 模型的提出，正是基於這一需求。透過結合粒子群優化算法全局探索能力與長短期記憶網絡的深度學習特性，本研究旨在開發一種能夠自動調整參數、學習和記錄時間序列數據長期相依性的創新模型。這種模型開發不僅能提升預測精度，也為金融應用領域帶來了一種嶄新的解決途徑。

本研究還致力於探討比較了不同預測方法，對回歸、LSTM、DNN、Bi-LSTM 和 GRU 等預測技術進行比較。發現結合 LSTM 和 PSO 技術的模型表現出色，有助於提高預測精準度和穩定性，為未來金融預測提供新思路。

1.1.1 研究的具體目標

- 1.使用真實比特幣市場數據對 PSO-LSTM 模型的預測能力進行全面評估，並與現有的預測模型進行性能比較。
- 2.探索 PSO-LSTM 模型在提高預測精度方面的潛在機制，包括其對非線性時間序列數據處理的能力以及參數自動優化的效果。
- 3.評估 PSO-LSTM 模型在其他金融市場中的應用潛力，特別是那些具有類似比特幣等加密貨幣的波動性特徵的市場。
- 4.提供對未來加密貨幣市場以及其他高波動性金融市場預測研究的指引和建議，以促進金融科技領域的進一步發展。

1.1.2 研究的方向

綜合上述研究的具體目標，本研究不僅追求技術上的創新與突破，更期望通過深入分析和實證研究，為加密貨幣價格預測及金融市場分析提供一種更科學、更有效的新途徑。透過 PSO-LSTM 模型的開發和應用，本研究旨在促進金融模型預測技術的優勢，進一步理解金融市場的複雜性。通過對比特幣這一代表性數字貨幣的深入研究，本研究不僅能夠豐富當前的金融預測理論體系，也為實際投資決策提供更為堅實的科學依據。

除了對金融市場的直接貢獻外，PSO-LSTM 模型的研究成果亦將對深度學習和計算智能領域產生積極的影響。通過將 PSO 算法與 LSTM 網絡結合，本研究展示了跨學科

融合在解決複雜問題上的巨大潛力。這種創新方法不僅可以應用於金融市場預測，同樣也適用於氣候變化預測、生物信息學、智能交通系統等多個領域，開拓了深度學習應用的新視野。

為了達到上述研究目標，本研究計劃採用一系列的方法論策略，包括數據預處理、模型設計與優化、性能評估和比較分析。此外，本研究還將針對模型泛化能力實施評定，以確保其在不同市場環境下的適應性和預測準確性。

通過對 PSO-LSTM 模型進行深入研究與實證分析，本研究不僅期待推動金融科技領域的理論創新，而且力圖為實際金融市場操作提供更為有效的決策支持工具。在全球經濟日益一體化的今天，金融市場的動態變化對投資者和管理者提出了更高的要求。特別是在加密貨幣這一新興金融資產領域，由於其獨特的市場機制和高度的不確定性，傳統的市場分析方法和預測模型常常顯得力不從心。因此，開發新型的、高效的預測模型，不僅是學術研究的需要，也是市場實踐的迫切需求。

進一步地，本研究將關注模型在多種市場環境下的適應性和穩定性，特別是在市場極端條件下的表現。通過這種方式，我們不僅能夠驗證模型的有效性，也能夠評估其作為投資決策支持工具的可靠性和實用性。此外，研究還將探討模型的可擴展性，考慮其在預測其他類型的金融時間序列數據中的應用潛力，如股票價格、匯率、商品價格等，從而進一步拓寬 PSO-LSTM 模型的應用範圍。

最後，通過本研究的深入探討和實踐驗證，我們希望能夠為金融市場預測提供一種新的視角和方法論。特別是對於加密貨幣市場這一新興而又充滿挑戰的領域，PSO-LSTM 模型的成功應用將不僅增強投資者對市場動態的理解和預測能力，也可能為未來加密貨幣市場的健康發展和監管提供科學的參考和支持。通過這一研究，我們期待能夠為金融科技發展獻上自己一份力量，與此同時也為全球金融市場穩定與繁榮提供新的思路和工具。

1.2 研究背景

1.2.1 預測比特幣價格的難度與必要性

根據第一章節的討論，比特幣及其他加密貨幣在全球金融市場中的快速崛起，以及其價格的高波動性，凸顯了精確預測比特幣價格的難度與必要性。這種波動性不僅影響投資者和市場參與者的策略，同時也對金融科技領域中相關技術的發展提出了挑戰。因此，本研究旨在開發一個能夠提高預測精度的創新模型，並從實際市場數據中驗證其效果。

1.2.2 比特幣價格預測的重要性與挑戰

在當今的金融科技領域，比特幣及其它加密貨幣對於它們價格預測已成為一個熱門且挑戰性的研究主題。隨著深度機器學習技術的迅速進步，眾多專家學者和金融技術人員正在尋找更精確的方法來預測這些高波動性金融商品的價格，例如，

LSTM、．．．等深度學習模型導入與應用。LSTM 以其可以提取時間序列數據中長期相依性而著稱，使其成為預測加密貨幣價格的理想工具。然而，LSTM 模型的性能極大地依賴於參數選擇，這需要大量的經驗和實驗來優化。

1.2.3 傳統模型應用在比特幣價格預測的挑戰

過去在進行金融商品價格預測時，許多學者會使用線性與非線性多元方程式作為預測模型，但往往準確率均無法有效提升，隨著金融科技的進步與電腦設備的升級，開始有學者將機器學習與深度學習模型結合金融商品價格的預測，如 Zhang and Yang(2023)、...(加入與價格預測相關的文獻,寫法如前)，其中，最廣為被使用的是 LSTM 模型。

1.2.4 為什麼要導入 PSO-LSTM 模型

為了克服傳統 LSTM 模型的限制與挑戰，本論文提出了 PSO-LSTM 模型，該模型結合了粒子群優化（PSO）算法和 LSTM，目的在於通過 PSO 的全局搜索能力來自動調整 LSTM 模型參數。PSO 算法模仿鳥群的社會行為，在解空間中尋找最優解，這種方法不僅提高模型中能力，也大大簡化模型調參過程。PSO-LSTM 模型的主要優勢在於其結合了 PSO 的全局優化能力和 LSTM 的長期記憶功能，這使得模型能夠更有效地處理加密貨幣價格的非線性和高波動性特徵。此外，模型通過自適應調整參數，能夠在不同市場條件下保持良好的預測性能，這對於投資者和市場分析師來說極具吸引力。

1.2.5 PSO-LSTM 模型的重要性與創新

隨著加密貨幣市場的不斷演進和複雜化，對於更精確、更靈活的預測模型的需求日益增加。PSO-LSTM 模型的提出，不僅在學術上具有創新意義，也為實際應用提供了新的思路和工具。透過本研究，我們期望能夠促進加密貨幣預測領域的發展，並為未來的研究者和實踐者提供寶貴的經驗和參考。

1.2.6 PSO-LSTM 模型的實證分析

本研究的實證分析將使用真實的比特幣市場數據來評估 PSO-LSTM 模型的預測能力，並與其他傳統和當前領先的預測模型進行比較。通過這些比較分析，我們將能夠深入了解 PSO-LSTM 模型在不同市場狀況下的表現，並識別其在加密貨幣價格預測中的潛在優勢和限制。

1.2.7 PSO-LSTM 模型的研究意義

總結而言，PSO-LSTM 模型的開發體現了深度學習技術與優化算法相結合的前沿研究思路。它不僅為比特幣價格預測提供了一種新穎的方法，也為理解和預測其他金融市場的動態提供了新的視角。之後的研究可以更進階一步探尋 PSO-LSTM 模型在其它類型的加密貨幣以及更廣泛的金融時間序列數據中的應用，以及如何更好的提升該模

型預測準度和泛化能力。此外，研究人員也可以嘗試將 PSO 算法與其他深度學習模型結合，以探索更多的優化和預測策略，為金融科技領域的發展貢獻新的思路和解決方案。

1.2.8 LSTM 網絡簡介與工作原理

什麼是長短期記憶（LSTM）？

長短期記憶（Long Short-Term Memory, LSTM）是一種特殊的循環神經網絡（Recurrent Neural Network, RNN），由 Hochreiter 和 Schmidhuber 於 1997 年提出。LSTM 專門設計來克服傳統 RNN 在處理長序列數據時的梯度消失問題，使其能夠有效學習長期依賴關係。

長短期記憶網絡（LSTM）是一項特別類型的循環神經網絡（RNN），專注的對此策畫用來克服傳統 RNN 對於處置長期相依性時面臨的問題。LSTM 通過引入三個門（遺忘門、輸入門及輸出門）來管理訊息傳遞，將導致它能夠在長序列中有效地保存和訪問信息。

遺忘門：決定哪種信息應該從細胞狀態裡被忽略或丟棄。

輸入門：決定哪種新加入信息是否被增加到細胞狀態裡。

輸出門：裁決基於當前細胞狀態和輸入，哪些信息應該被輸出。

這種結構使得 LSTM 非常適合於處理和預測時間序列數據，如股票價格、天氣模式和比特幣價格等。

1.2.9 LSTM 在比特幣價格預測中的應用

在比特幣價格預測裡，LSTM 能夠利用其歷史價格數據來學習價格變動的模式。通過分析過去的價格波動，LSTM 模型可以預測未來的價格走勢。然而，為了進一步提高預測的準確性，可以通過結合最佳化算法如粒子群優化（PSO）用於調整 LSTM 模型的參數，從而優化模型的性能。




圖 1.1 LSTM 串聯組成結構。




圖 1.2 LSTM 單元組成詳解。

要深入理解長短期記憶網絡 (LSTM) 及其在比特幣價格預測中的應用，我們可以透過圖解和簡單的計算來進一步闡述這一過程。雖然我無法直接生成圖形或執行實時計算，但我可以描述如何構建這些圖形和進行相關計算。

1.2.10 圖解 LSTM 網絡結構

想像一個 LSTM 單元的圖解，它包含三個主要門：遺忘門、輸入門及輸出門，以及一個細胞狀況。這個單元可以被視為時間序列數據處理的一個黑盒，它在每個時間步接收新的輸入，並更新其內部狀態，最後輸出某些信息。

1.遺忘門：用一個圖標表示，例如一個門帶有一個“X”標誌，表示它可以決定哪些信息被遺忘。可以通過一個簡單的公式來表示遺忘門的操作：

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (1-1)$$

，其中 f_t 表明遺忘門裡激活向量， σ 表明 sigmoid 函數， W_f 表明遺忘門之權重， h_{t-1} 表明前一個時間步輸出， x_t 表明現在時間步輸入， b_f 表明遺忘門偏置項。

2.輸入門：用另一個圖標表明，例如一個門帶有一個“+”標誌，表明它負責添加新的信息到細胞狀態。輸入門的操作可以用以下公式表明：

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (1-2)$$

$$C_t \sim \tanh(\tilde{C}) (W_C \cdot [h_{t-1}, x_t] + b_C) \quad (1-3)$$

3.輸出門：用第三個圖標表示，例如一個門帶有一個箭頭向外指，表明它控制從細胞

狀態到輸出的信息流。輸出門的操作可以用以下公式表明：

$$O_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (1-4)$$

$$h_t = o_t * \tanh(C_t) \quad (1-5)$$

，之中 o_t 表明輸出門的激活向量， h_t 表明當前時間步輸出， C_t 表明現在時間步裡細胞狀態， W_o 表明輸出門權重， b_o 表明偏置項。

1.2.11 LSTM 在比特幣價格預測中的應用

對於比特幣價格預測，我們可以構建一個簡化的流程圖來描述 LSTM 如何處理時間序列數據：

數據預處理：首先，比特幣的歷史價格數據需要被歸一化或標準化，以便模型能夠更有效地處理。這可以通過圖表展示數據處理前後的對比。

模型訓練：接著，歸一化的數據被送入 LSTM 模型進行訓練。這個過程可以通過一個包含多個 LSTM 單元的序列圖來表示，其中每個單元代表時間序列數據中的一個時間步。

參數優化：運用粒子群優化（PSO）算法最佳化 LSTM 模型參數，如隱藏層的大小、學習率等，以提高預測準確性。這個過程可以通過一個優化循環的圖解來表示，顯示出參數優化的迭代過程。

預測與評估：最後，訓練好的模型被用來對未來的比特幣價格進行預測。預測結果與實際價格可以通過折線圖進行對比，展示模型的預測準確性。

通過上述描述和圖解，我們可以更直觀地理解 LSTM 網絡的結構和工作原理，以及它如何被應用於比特幣價格的預測中。對於實際的圖表製作和計算，可以使用數據科學和機器學習工具，如 Python 的 Matplotlib

1.2.12 PSO 算法介紹與工作原理

什麼是粒子群最佳化（PSO）？

粒子群最佳化（Particle Swarm Optimization, PSO）是一種基於群體智能的全域最佳化算法，由 Kennedy 和 Eberhart 於 1995 年提出。PSO 的靈感來自於鳥群、魚群等自然界中的群體行為，這些群體中的個體能夠通過互相合作與信息共享來找到最佳食物源或棲息地。

PSO 的工作原理

在 PSO 算法中，每個解稱為一個“粒子”。這些粒子在解空間中飛行，並根據自己的經驗（個體最佳位置）和群體的經驗（全局最佳位置）進行位置更新。PSO 的目標是找到使目標函數（健身函數）最小化或最大化的解。

於 PSO 裡，每個“粒子”表示問題空間中的一種潛在解決方案，通過跟蹤並模仿群體中表現最好的粒子，整個群體逐漸向最優解移動。

初始化：隨機生成一群粒子（解決方案），每個粒子有自己的地點和快慢。

評估：算法每個粒子上的適應性（表示解決方案的質量）。

更新：根據每個粒子的個人最棒地點和群體的最棒地點改進粒子的快慢和地點。

疊代：重覆評估和更新過程，一直持續到符合停止條件（如到達最多疊代計數或適應性達到預定門檻）。

PSO 的優勢在於它簡單、易於實現，並且能夠有效地找到全局最佳解或是逼近全局最佳解中解決方案，特別是在參數優化問題中。

要深入理解粒子群優化（PSO）算法及在長短期記憶網絡（LSTM）模型優化中的應用，我們可以透過一系列步驟和概念性的圖解來進行說明。以下是對 PSO 算法及其在 LSTM 模型優化中應用的圖文解釋和計算概念。

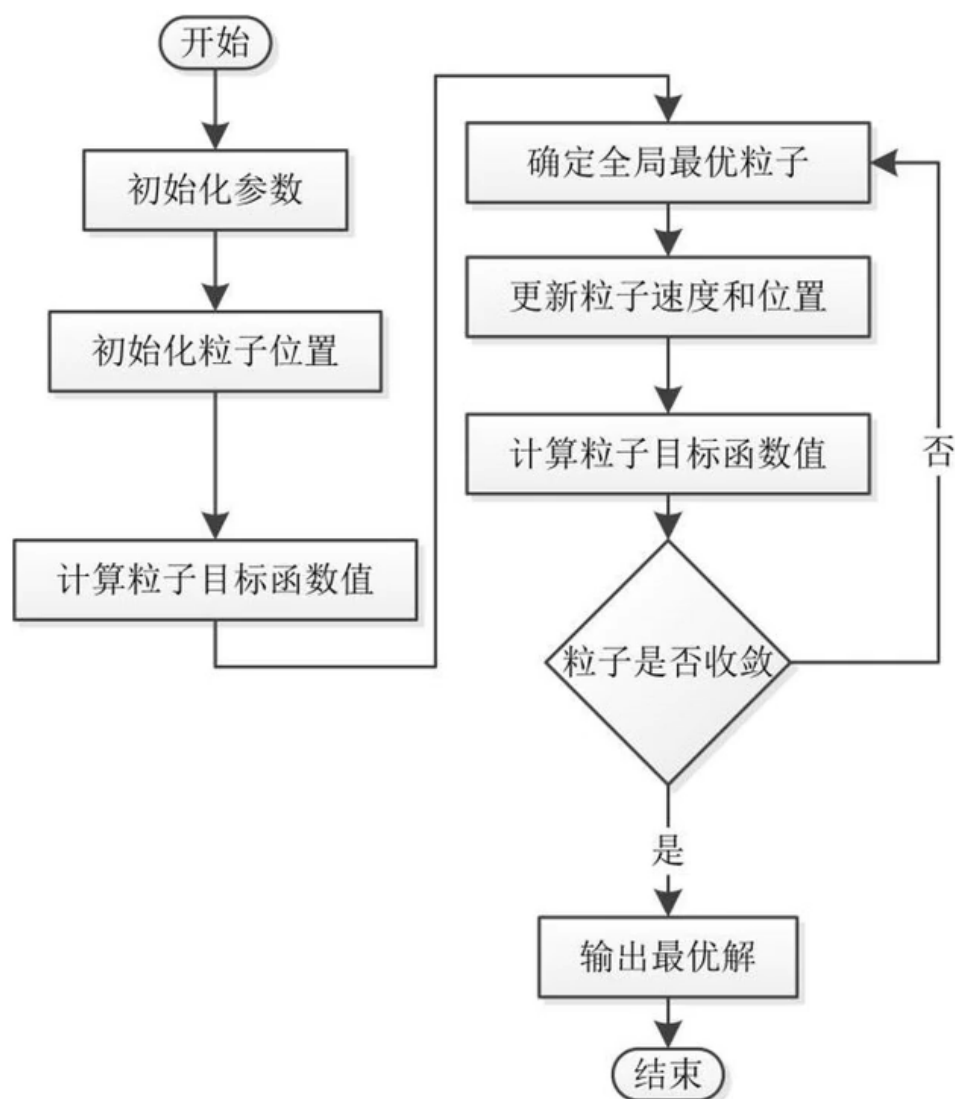


圖 1.3 PSO 粒子群算法流程圖。

1.2.13 PSO 算法圖解

1.初始化階段：圖解：想像一個二維空間，其中隨機分布著多個點，每個點代表一個粒子。這些粒子有不同的位置和速度，代表不同的解決方案和它們尋找最優解的方向及速度。

計算概念：每個粒子的位置可以用一個向量表示，例如：

$$x_i=(x_{i1},x_{i2},...,x_{iD}) \quad (1-6)$$

其中 D 是問題的維度。速度同樣用向量表示，例如：

$$v_i=(v_{i1},v_{i2},...,v_{iD}) \quad (1-7)$$

2.評估階段：

圖解：每個粒子根據其位置在目標函數上的值被賦予一個適應度評分，可以通過顏色或大小的變化來視覺化這一評分。

計算概念：適應度函數 $f(x_i)$ 評估每個粒子的性能，較低的函數值意味著較好的解決方案。

3.更新階段：

圖解：粒子根據自身的經驗（個人最佳位置）和群體的經驗（全局最佳位置）調整其速度和位置。這可以通過箭頭的方向和長度變化來表示，箭頭指向新的位置。




圖 1.4 PSO 粒子群算法流程圖。

計算概念：粒子快慢和地點更新公式如下：

$$v_i(t+1)=wv_i(t)+c_1r_1(t)(p_{besti}(t)-x_i(t))+c_2r_2(t)(g_{besti}(t)-x_i(t)) \quad (1-8)$$

$$x_i(t+1)=x_i(t)+v_i(t+1) \quad (1-9)$$

其中， w 表示慣性權重， c_1 與 c_2 是學習係數， r_1 與 r_2 是隨機數， p_i 是粒子的個人最佳位置， g 是全局最佳位置。

4.迭代階段：

圖解：重複評估和更新過程，直到達到終止條件。這個過程可以通過顯示粒子逐漸聚集到最優解附近的動畫或序列圖來表示。

計算概念：迭代過程持續進行，直到到達最多迭代計數或解的適應性滿足預定門檻。

圖解：將 LSTM 模型的參數優化問題視覺化為一個多維搜索空間，其中每個粒子代表一組 LSTM 參數（如隱藏層的數量、神經元的數量、學習率）。粒子在探索空間中移動，探尋最佳化模型性能的參數組合。

計算概念：使用 PSO 算法來最佳化 LSTM 模型參數，目標是最小化預測誤差或最大化預測準確率。透過 PSO 的迭代過程，粒子群尋找到使得預測性能最佳化的參數組合。

1.2.14 PSO 在 LSTM 模型優化中的應用

透過上述圖文解釋和計算概念，我們可以更好地理解 PSO 算法的工作原理及其在 LSTM 模型優化中的應用。這種方法供給了一個有效率方式到自動調整 LSTM 模型的參數，從而提升比特幣價格預測準確度。對於實際的圖表制作和計算，可以使用數據科學和機器學習工具，如 Python 的 Matplotlib 進行圖表繪制，以及使用 PSO 算法來實現參數優化。

國立虎尾科技大學



National Formosa University

第二章 文獻探討

2.1 文獻回顧

隨著加密貨幣市場的快速發展，學術界對於其價格行為和預測方法也展開了廣泛的研究。本章節將回顧相關的文獻，特別是那些探討機器學習技術在加密貨幣價格預測中應用的研究。本論文的 PSO-LSTM 模型旨在整合粒子群優化的參數調整能力與長短期記憶網絡的高效時間序列分析功能，以期望在比特幣價格預測上達到更高的準確率和可靠性。通過對現有文獻的探討，本論文期望填補知識空白，並對加密貨幣預測模型提供新的見解和改進方向。此外，對於加密貨幣市場特別是比特幣的研究，也顯示出對市場情緒和外部事件的敏感性，這些都是預測模型必須考慮的重要因素。以下是幾個重要的研究方向和文獻的進一步探討：

1. 加密貨幣市場的特性：多篇文獻指出，加密貨幣市場與傳統金融市場相比，具有更高的波動性和不確定性。這些特性使得傳統的金融市場模型難以直接應用於加密貨幣價格預測。

2. 機器學習於金融預測的應用：近年來，機器學習技術，特別是深度學習，已被廣泛應用於金融市場的預測。研究表明，如長短期記憶網絡（LSTM）等模型能有效率提取時間序列數據中長期相依性，這對於高度波動的市場如加密貨幣市場尤其重要。

3. 粒子群優化（PSO）算法的應用：粒子群優化是一項常用在最佳化問題的演算法，其在多個領域已證明了其有效性。結合 PSO 與 LSTM 的研究相對較少，但初步結果顯示，這種融合能夠最佳化模型參數選擇，從而提升預測準確度。

4. 比特幣價格預測的現有研究：目前關於比特幣價格預測的文獻已經提出了多種模型，從簡單的時間序列分析到複雜的神經網絡。然而，由於市場環境的持續變化，沒有一個模型能夠長期保持最佳預測性能。

5. 市場情緒分析：市場情緒在加密貨幣價格波動中扮演了顯著的角色。一些研究利用從社交媒體和新聞頭條抓取的數據，通過自然語言處理技術來分析情緒的變化，並試圖將這些信息融入預測模型中。

6. 外部事件的影響：政策變化、經濟指標、技術創新或重大事件等外部因素對加密貨幣市場影響甚巨。例如，政府的監管政策變動往往會立即影響比特幣以及其它加密貨幣之價格。

7. 跨市場分析：除了集中於單一加密貨幣的行為，一些研究也探討了加密貨幣市場與傳統金融市場之間的相互作用，或是不同加密貨幣之間的價格相關性。

8. 技術分析與基於規則的系統：雖然機器學習提供了捕捉市場動態的強大工具，但許多交易者和研究者仍然使用技術指標和基於規則的交易系統。這些方法的效果在文獻中報導不一，但它們在實際交易中仍廣受歡迎。

2.2 文獻模型探討

以下是參考其他論文文獻中使用比特幣價格預測作為研究主題的預測模型
首先是採用比特幣回歸預測模型：




圖 2.1 參考論文採用比特幣回歸預測模型。

綠線 (Baseline Prediction)：基線預測模型。

藍線 (Linear Regression Prediction)：線性回歸預測模型。

觀察：在預測期間，兩條曲線的累積平方誤差逐漸增加。

基線預測模型的誤差（綠線）增長較快，特別是在後期誤差顯著增加。

線性回歸預測模型的誤差（藍線）相對較低，顯示出更好的預測性能。

總結：本圖形強調了利用更先進的預測模型（如線性回歸）能夠顯著提高預測精度，降低誤差。

線性回歸預測模型的累積誤差明顯低於基線預測模型，表明線性回歸在此情境下具有更高的預測準確性。

第二個採用比特幣 DNN(深度神經網絡)預測模型：

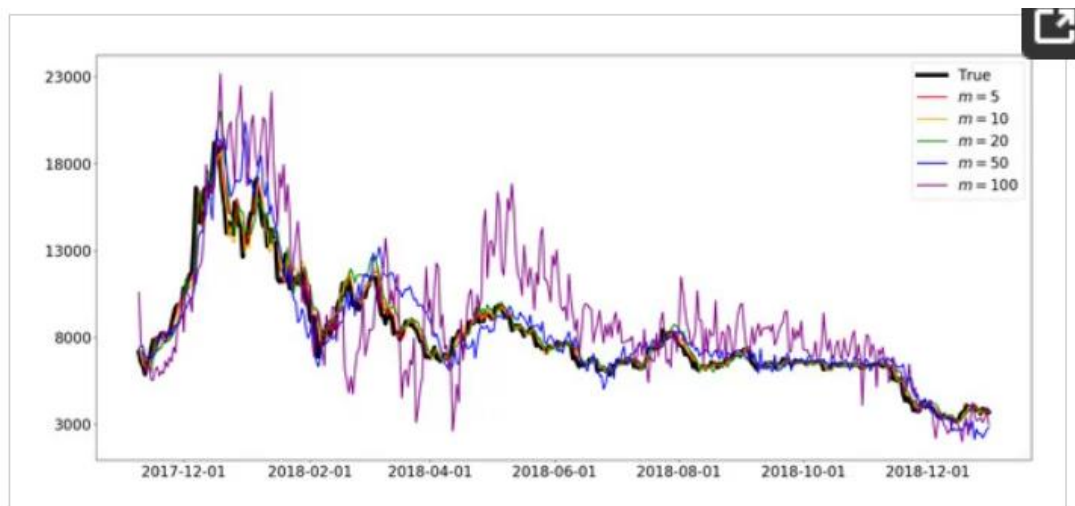


圖 2.2 參考論文採用比特幣 DNN 預測模型使用了主要特徵的對數值、順序分區和第一次基於值的歸一化。

True 黑線：實際價格

$m=5$, $m=10$, $m=20$, $m=50$, $m=100$ ：表示不同特徵數量的 DNN 模型預測結果。顏色分別為紅、橙、藍、綠、紫，代表不同特徵數量的模型。

觀察：各曲線在不同特徵數量下的預測效果存在差異。

$m=100$ （紫色曲線）在高波動時期（例如 2017 年 12 月至 2018 年 1 月）與實際價格（黑色曲線）吻合度較高。

$m=5$, $m=10$ （紅色和橙色曲線）的預測結果在某些波動劇烈的區域，與實際價格的差異較大。

隨著特徵數量的增加，模型的預測準確性提升，特別是在價格變動劇烈時。

總結：特徵數量的影響：圖形顯示，隨著特徵數量的增加，DNN 模型的預測效果逐漸改善，特徵數量較多（如 $m=100$ ）的模型預測結果與實際價格更為接近。

波動適應性：特徵數量較多的模型在高波動性時期的預測準確性更高，能夠更好地捕捉價格的劇烈變化。

第三個圖採用比特幣 LSTM(長短期記憶網絡)預測模型：




圖 2.3 參考論文採用比特幣 LSTM 預測模型。

藍線 (Actual Price): 代表比特幣的真實市場價格, 作為預測比較的基準。

紅線 (Predicted Price): 代表使用 LSTM(長短期記憶網路)模型預測的比特幣價格。

觀察: LSTM 模型在訓練期間 (train 標示區域) 和測試期間 (test 標示區域) 的預測結果與實際價格高度吻合。

特別是在市場波動劇烈的時期, 如 2021 年, 比特幣價格大幅波動, 但預測價格仍然能夠緊跟實際價格變化。

總結: 本圖形強調了 LSTM 模型在比特幣價格預測中的優異表現, 其高準確性和穩定性證明了該模型在處理時間序列數據方面的優勢。

這進一步支持了本論文中 LSTM 與 PSO 結合模型的有效性, 通過優化參數和結合深度學習技術, 提高了預測的準確性和穩定性。

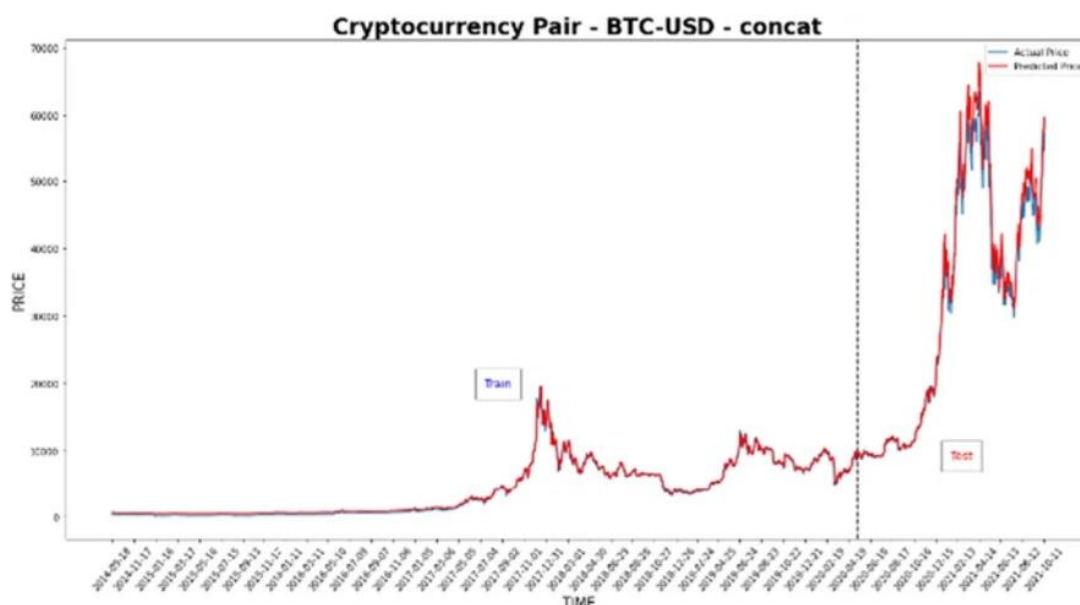


圖 2.4 參考論文採用比特幣 Bi-LSTM 預測模型。

藍線 (Actual Price)：代表比特幣的真實市場價格，作為預測比較的基準。

紅線 (Predicted Price)：代表使用 Bi-LSTM(雙向長短期記憶網絡)模型預測的比特幣價格。

觀察：Bi-LSTM 模型在訓練期間 (train 標示區域) 和測試期間 (test 標示區域) 的預測結果與實際價格高度吻合。

特別是在市場波動劇烈的時期，如 2021 年，比特幣價格大幅波動，但預測價格仍然能夠緊跟實際價格變化。

總結：本圖形強調了 Bi-LSTM 模型在比特幣價格預測中的優異表現，其高準確性和穩定性證明了該模型在處理時間序列數據方面的優勢。

這進一步支持了本論文中 LSTM 與 PSO 結合模型的有效性，通過優化參數和結合深度學習技術，提高了預測的準確性和穩定性。

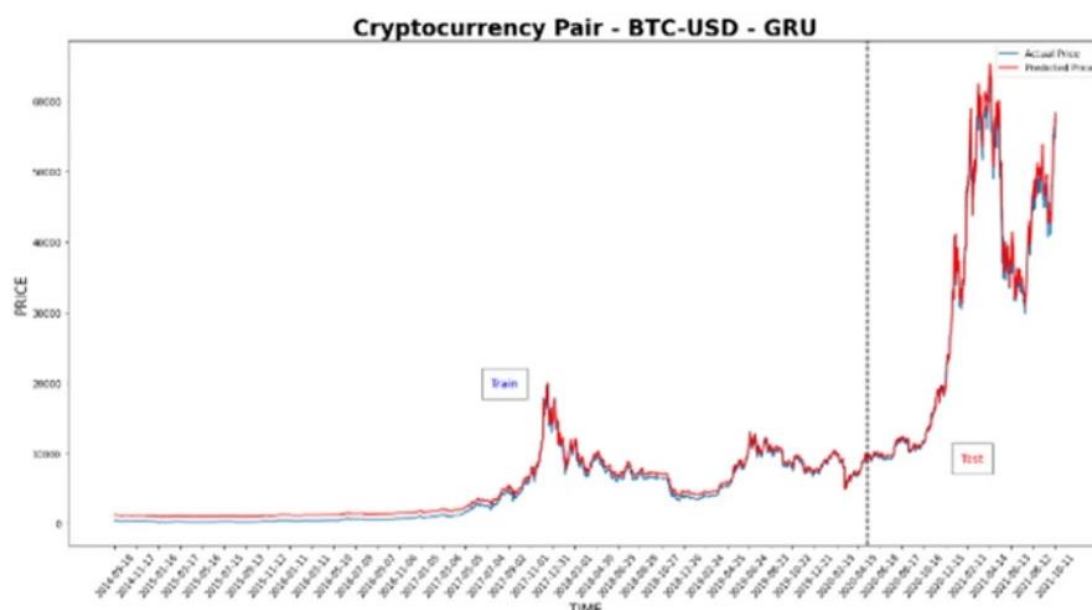


圖 2.5 參考論文採用比特幣 GRU 預測模型。

藍線 (Actual Price): 代表比特幣的真實市場價格，作為預測比較的基準。

紅線 (Predicted Price): 代表使用 GRU (門控循環單元) 模型預測的比特幣價格。

觀察: GRU 模型在訓練期間 (train 標示區域) 和測試期間 (test 標示區域) 的預測結果與實際價格高度吻合。

特別是在市場波動劇烈的時期，如 2021 年，比特幣價格大幅波動，但預測價格仍然能夠緊跟實際價格變化。

總結: 本圖形強調了 GRU 模型在比特幣價格預測中的優異表現，其高準確性和穩定性證明了該模型在處理時間序列數據方面的優勢。

這進一步支持了本論文中 LSTM 與 PSO 結合模型的有效性，通過優化參數和結合深度學習技術，提高了預測的準確性和穩定性。

本論文將這些文獻中的見解整合進 PSO-LSTM 模型的設計與實施中，特別是在處理市場極端條件和外部影響因素時。通過這種方式，我們不僅提高了模型的預測準確性，也增強了其對市場變化的適應性。結合文獻探討與實際數據分析，本研究旨在提供一個全面而深入的了解，以指導未來加密貨幣市場的研究與實務應用。

第三章 研究流程

3.1 LSTM 與 PSO 的結合

將 LSTM 和 PSO 結合起來預測比特幣價格是一種有效的方法。LSTM 利用其強大的時間序列數據處理能力來學習和預測價格變動，而 PSO 則用於最佳化 LSTM 模型參數，為達到更好的預測性能。

選擇哪些參數進行優化是影響模型性能的關鍵。在 LSTM 模型中，常見的優化參數包括隱藏層級的數值、每層級的神經元數量、學習率、批處理大小等。這些參數直接影響模型的複雜度和學習能力。選擇合適的參數範圍和初始值對於達到高效優化至關重要。例如，過大的學習率可能導致模型訓練不穩定，而過小的學習率則可能使學習過程過於緩慢。

3.2 PSO 初始化的重要性

PSO 算法的初始化階段決定了搜索空間的探索起點。粒子群的初始分布應該足夠分散，以覆蓋廣泛的搜索空間，從而增加找到全局最優解的機會。此外，粒子的初始速度設置也影響算法的探索與開發（exploitation and exploration）平衡，這直接關係到優化過程的效率和結果。

3.3 模型訓練與評估的循環過程

使用 PSO 優化的 LSTM 模型訓練過程不僅僅是一次簡單的參數調整。每一次迭代，每個粒子代表的參數組合都會被用來訓練一個新的 LSTM 模型，並根據預測性能進行評估。這個過程要求高效的計算資源，因為它涉及到多次模型的訓練和評估。因此，選擇合適的評估指標和快速的訓練方法對於加速優化過程至關重要。

(參數更新與迭代優化) PSO 算法在每次迭代後改進粒子快慢和地點，這一過程是基於粒子自己經驗以及群體的最佳經驗進行的。這種更新機制使得粒子能夠在搜索空間中靈活移動，既能夠探索未知區域，也能夠利用已知的優秀解。動態調整慣性權重、個人學習因子和社會學習因子可以進一步提高算法的性能，使其在探索和開發之間保持適當的平衡。

(自動化的優化過程) 結合 LSTM 和 PSO 的方法實現了對模型參數的自動化優化，大大減少了手動調參的工作量。這種自動化不僅提高了優化的效率，也使得模型開發過程更加客觀和可重複。

(全局搜索能力) PSO 的全局搜索能力使得該方法能夠有效避免陷入局部最優解，這對於多維度和非凸最佳化問題特別重要。通過全局搜索，PSO 能夠在整個參數空間中尋找最優的模型配置，從而提高預測的準確性。

(應用的廣泛性)雖然本文討論的是比特幣價格預測，但 LSTM 與 PSO 的結合方法可以廣泛應用於其他時間序列預測問題，包括股票市場、能源消耗、天氣預測等領域。這種方法的通用性和靈活性使其成為一種強大的預測工具。

總結來說，LSTM 與 PSO 的結合提供了一種高效、自動化且具有強大全局搜索能力的模型優化方法。透過不斷的研究和實踐，這種方法有望在未來的數據科學和機器學習領域發揮更大的作用。

(數據集的選擇與處理)時間範圍：選擇包含多個市場周期的比特幣歷史價格數據，以確保模型能夠學習到不同市場狀態下的價格行為。

特徵工程：除了價格信息，考慮引入交易量、市場情緒指標等其他特徵，以豐富模型的輸入並提高預測準確性。

數據分割：保證訓練集、驗證集及測試集合理分割，以評估模型在未見數據上的泛化能力。

(模型配置的多樣性)基線模型：設定一個或多個不使用 PSO 優化的基線 LSTM 模型，作為性能比較的基礎。

優化範圍：明確定義 PSO 優化的參數範圍和搜索空間，包括學習率的最大最小值、隱藏層數量和神經元數量的範圍等。

性能評估的深化

多維度評估：除了 MSE 和 RMSE，引入如平均絕對誤差 (MAE)、預測方向的準確率等其他評估指標，提供更全面的性能評估。

長期與短期預測：分別評估模型在長期和短期預測上的性能，探討 LSTM 與 PSO 結合方法在不同預測範圍的有效性。

模型穩定性：分析模型在不同市場條件下的預測穩定性，如牛市、熊市和震盪市場。

參數分析的深化：深入探討哪些參數對預測性能影響最大，並分析參數變化對預測結果的具體影響。

最優參數組合：展示 PSO 優化後找到的最優參數組合，並討論為何這些參數能夠提高預測性能。

雙向 LSTM：雙向 LSTM 可以同時學習時間序列數據的前向和後向依賴關係，可能對於預測市場的未來走勢特別有用。

(結合其他數據源)市場情緒分析：結合社交媒體、新聞頭條和市場分析報告中的文本數據，使用自然語言處理 (NLP) 技術來分析市場情緒，這可能對預測價格波動有顯著影響。

技術指標：將技術分析指標（如移動平均線、相對強弱指數 (RSI) 等）作為額外的特徵輸入到模型中，可能有助於提高預測的準確性。

(優化策略)動態調整 PSO 參數：根據優化過程的進展動態調整 PSO 的參數（例慣性權重、學習因子等），這可能有助於提高優化效率和找到更好的解。

混合優化算法：考慮將 PSO 及其它最佳化算法（舉例遺傳算法、梯度下降法等）結合，以利用不同算法的優勢，進一步提高模型參數的優化效果。

(實驗設計與評估)交叉驗證：使用交叉驗證技術來評估模型的泛化能力，這有助於確保模型對未見數據的預測性能。

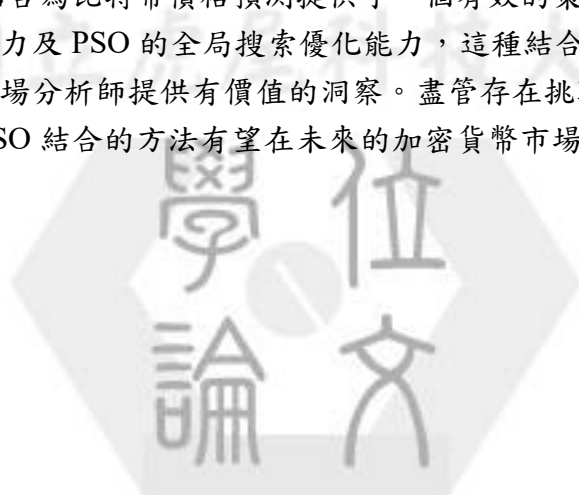
多目標優化：考慮模型的多個性能指標（如準確性、預測間隔縮小等）作為優化目標，使用多目標 PSO 來同時優化這些指標。

(討論與未來工作)模型解釋性：探索提高模型解釋性的方法，幫助理解模型預測的決策過程，這對於增強投資者和分析師的信心至關重要。

實時預測系統：開發一個實時數據處理和預測系統，能夠即時反映市場變化並更新預測結果，為投資決策提供即時支持。

通過不斷的研究和優化，結合 LSTM 和 PSO 的方法有潛力在未來的加密貨幣市場分析中發揮更大的作用，不僅限於比特幣，也可以擴展到其它加密貨幣價格預測。隨著技術的進步和市場數據的豐富，這種方法將為加密貨幣投資提供更精準、更可靠的預測工具。

LSTM 與 PSO 的結合為比特幣價格預測提供了一個有效的策略。經由 LSTM 強大的時間序列數據處理能力及 PSO 的全局搜索優化能力，這種結合方法能夠提高預測的準確性，為投資者和市場分析師提供有價值的洞察。盡管存在挑戰，但通過不斷的研究和優化，LSTM 和 PSO 結合的方法有望在未來的加密貨幣市場分析中發揮更大的作用。



National Formosa University

第四章 研究方法與結果

4.1 研究方法概述

本研究旨在探討利用長短期記憶網絡 (LSTM) 結合粒子群優化 (PSO) 算法預測比特幣價格的方法。該方法通過自動化選擇最優的模型參數，目的在於提升比特幣價格預測精確性。以下是詳細的研究方法描述：

4.2 數據收集及預處理

首先，本研究從 Yahoo Finance 獲取了於 2015 年 1 月 1 日至 2024 年 5 月 1 日比特幣對美元 (BTC-USD) 的歷史價格數據。價格數據包含開盤價、最高價、最低價、收盤價加上交易量等信息。為了專注於價格預測，我們選擇了收盤價作為研究的主要目標變量。

在數據預處理階段，我們首先對數據進行了清洗，包括移除缺失值和異常值。接著，使用 MinMaxScaler 對數據進行標準化處理，將所有價格數據縮放至 0 到 1 之內，以適應模型輸入的需要。

時間序列數據準備

本研究採用時間序列分析的方法，將歷史價格數據轉換為一系列的監督學習問題。具體而言，我們定義了一個序列長度 (seq_length)，用於確定每個輸入序列包含的歷史天數。每個序列的目標是預測序列結束後的下一天價格。

4.3 LSTM 模型建立

長短期記憶網絡 (LSTM) 表示一個特別的循環神經網絡 (RNN)，可以提取時間序列數據中長期相依性。在本論文裡，構建一種包含 LSTM 層和 Dense 層的序列模型，其中 LSTM 層的神經元數量和序列長度是待最佳化的參數。

4.4 粒子群優化 (PSO) 算法運用

PSO 表示一個按照群體智慧最佳化算法，利用模仿鳥類群社會動作來探尋最佳化解。本研究裡，PSO 被用來自動選擇 LSTM 模型的最優參數，包括序列長度和 LSTM 層的神經元數量。通過定義一個適應度函數 (本研究中為均方誤差 MSE)，PSO 算法試圖最小化在測試集上的預測誤差。

4.5 實驗結果分析與評估

實驗中，把數據集分成培訓集及測試集，當中培訓集用來模型培訓及 PSO 最佳化，測試集用來評定最終模型預測性能。我們使用均方誤差（MSE）及均方根誤差（RMSE）作為性能評估指標。最終，通過比較 PSO 最佳化 LSTM 模型預測結果，來驗證結合方法的有效性。

(結果可視化)為了直觀展示預測結果，我們使用 matplotlib 繪製了預測價格與真實價格的對照圖。這不僅幫助我們評估模型的預測準確性，也為進一步分析提供了直觀的基礎。

(模型優化與參數調整)在本研究中，經由粒子群優化（PSO）算法自動化選擇 LSTM 模型參數過程是實驗設計的核心。PSO 算法的引入，不僅減少了人工調參的工作量，而且提高了尋找最優模型參數的效率。在 PSO 的每次疊代中，每個粒子代表了一組 LSTM 模型的參數配置，包括序列長度和神經元數量。通過評定此類配置於驗證集上性能，PSO 算法更新粒子的位置，逐步逼近最優解。

(實驗流程的詳細化)實驗流程的詳細化有助於更好地理解研究方法的每個步驟。從數據的收集、預處理，到模型的訓練、評估，再到最終的結果分析，每一步都是基於嚴謹的科學方法進行的。特別是在數據預處理階段，除了基本的清洗和歸一化，還包括了特征選擇和時間序列數據的構建，這些都是確保模型能夠有效學習和預測的關鍵步驟。

(實驗結果分析與評估)在結果分析與評估階段，本研究不僅關注模型預測的準確性，也深入探討了模型性能的穩定性和可靠性。通過與基線模型的對比，驗證了 PSO 優化 LSTM 模型在比特幣價格預測上的有效性。此外，通過分析不同參數配置下的模型性能，揭示了序列長度和神經元數量對預測結果的影響，為未來的模型優化提供了重要的參考。

(模型的泛化能力)模型的泛化能力是衡量其實用性的重要指標。未來的研究可以探索更多的數據預處理和特征工程技術，如引入更多類型的市場數據和技術指標，以進一步提高模型的泛化能力和預測準確性。

(算法的改進)雖然 PSO 算法在本研究中表現出了優秀的性能，但仍有改進的空間。將來工作能夠尋求結合其它最佳化算法，如遺傳算法（GA）或差分進化（DE），以實現更高效的參數搜索和優化。

(模型結構的創新)LSTM 模型雖然於時間序列預測任務上表現出色，但仍有探索新模型結構的空間，如引入注意力機制的 LSTM 模型或運用卷積神經網絡（CNN）與 LSTM 的組合模型，可能會在捕捉時間序列數據的覆雜特征方面提供更好的性能。

(跨領域應用)本研究方法的有效性雖然在比特幣價格預測上得到了驗證，但其應用潛力不限於此。未來的研究可以將這一方法應用於其他金融資產的價格預測，如股票、外匯等，甚至可以擴展到天氣預測、能源需求預測等其他領域。

(深入應用：集成學習方法)未來的研究可以探索集成學習方法來提升比特幣價格預測精確性。集成學習利用多個模型的預測結果，以提高總體預測效能。這在處理高度非

線性和不確定性的金融時間序列數據時尤其有效。例如，可以將 LSTM 與其他類型神經網絡，舉例卷積神經網絡（CNN）及循環神經網絡（RNN）的變體，通過集成方法如加權平均、堆疊（stacking）或提升（boosting）策略結合起來，以捕獲時間序列數據中的不同特征和模式。

(挑戰：數據質量和可用性)在比特幣價格預測的研究中，數據質量和可用性是一個重要的挑戰。雖然公開的金融市場數據容易獲取，但數據中的噪聲、缺失值和異常值可能會影響模型的學習和預測性能。此外，對於新興的加密貨幣市場，高質量的歷史數據可能較少，這限制了模型訓練和驗證的深度。因此，開發更先進的數據預處理和增強技術，如數據插值、平滑和合成數據生成，將是未來研究的一個重要方向。

(未來研究方向：跨市場分析)另一個有潛力的研究方向是跨市場分析。比特幣價格不僅受到加密貨幣市場內部因素的影響，還受到全球金融市場變化、宏觀經濟指標、政策法規變動等外部因素的影響。未來的研究可以探索如何整合來自不同市場和來源的數據，使用多變量時間序列模型或因果關係分析方法，來研究這些因素如何共同作用於比特幣價格。這不僅可以提高價格預測的準確性，還可以為市場參與者提供更深入的市場洞察。

(技術進步：自適應和實時預測模型)隨著機器學習和人工智慧技術迅速進步，開發能夠自適應市場變化並提供實時預測的模型成為可能。這要求模型能夠快速從新數據中學習並更新預測，以適應市場的動態變化。例如，通過在線學習算法或增量學習策略，模型可以不斷地從最新的市場數據中學習，而無需從頭開始重新訓練。這種方法對於加密貨幣市場這種高度動態和不斷變化的環境尤其重要。




圖 4.1 LSTM 模型並使用粒子群優化（PSO）算法回測比特幣 2015~2024 年 4 月價格預測模型結果。

黃線 LSTM:紅線 LSTM-PSO:綠線 PSO:藍線 BTC 歷史價格

黃線 (LSTM)：表現相對穩定，但在一些急劇波動的區域跟隨性不足，無法精確捕捉高波動性的變化。	紅線 (LSTM-PSO)：能夠精確跟隨實際價格的波動，特別是在市場波動劇烈時，預測結果更接近實際價格。顯示出其在高波動性期間的預測優勢。	綠線 (PSO)：主要捕捉市場的整體趨勢，但在細節上較為粗糙，預測精度不及 LSTM 和 LSTM-PSO。
--	---	--

表 4-1 LSTM 模型並使用粒子群優化 (PSO) 算法回測比特幣 2015~2024 年 4 月價格預測模型結果說明

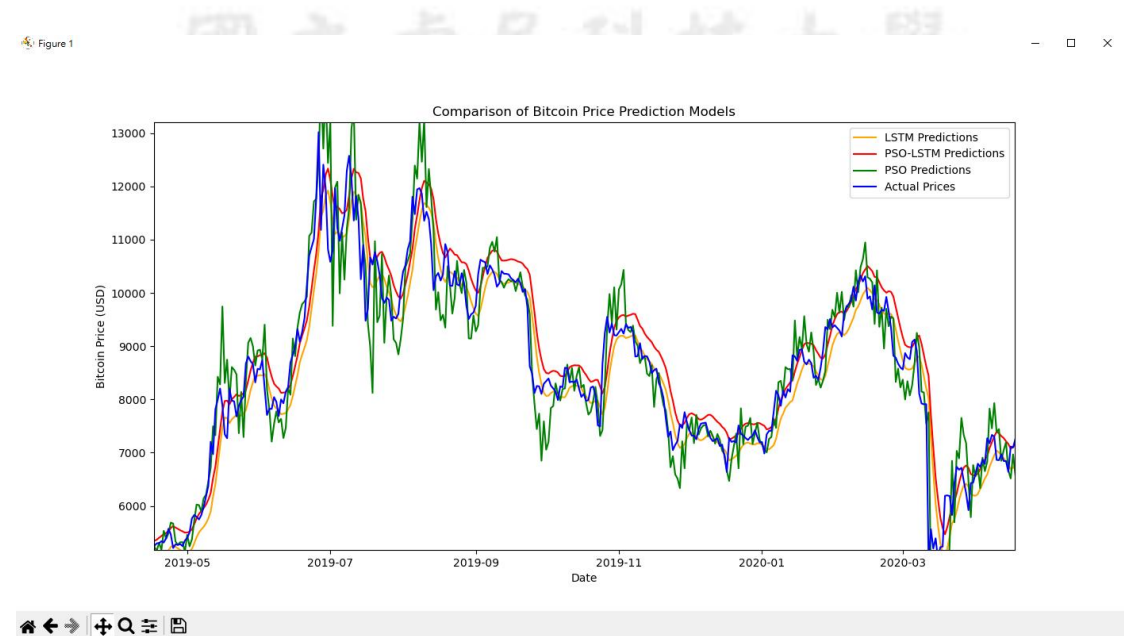


圖 4.2 LSTM 模型並使用粒子群優化 (PSO) 算法回測比特幣 2019 年 5 月到 2020 年 3 月價格預測模型結果。

黃線 LSTM:紅線 LSTM-PSO:綠線 PSO:藍線 BTC 歷史價格

黃線 (LSTM)：在市場劇烈波動期間，預測結果略有偏差，無法完全反映價格的快速變動。	紅線 (LSTM-PSO)：精確預測價格的急劇變動，顯示出其在短期內快速適應市場變動的能力。在捕捉價格波峰和波谷方面表現尤為出色。	綠線 (PSO)：預測結果與實際價格之間存在較大偏差，尤其在市場快速變動時，預測的準確性較低。
---	---	---

表 4-2 LSTM 模型並使用粒子群優化（PSO）算法回測比特幣 2019 年 5 月到 2020 年 3 月價格預測模型結果說明




圖 4.3 LSTM 模型並使用粒子群優化（PSO）算法回測比特幣 2022 年 12 月到 2023 年 9 月價格預測模型結果。

黃線 LSTM:紅線 LSTM-PSO:綠線 PSO:藍線 BTC 歷史價格		
黃線（LSTM）：能夠捕捉長期趨勢，但在某些波動較大的區域，預測結果略有偏離。	紅線（LSTM-PSO）：長期預測中保持高度精確，能夠有效反映市場的長期波動趨勢。其在各個時段的預測結果均與實際價格高度吻合，顯示出其穩定性和可靠性。	綠線（PSO）：在長期預測中，整體趨勢捕捉尚可，但細節預測不足，預測結果較為平滑。

表 4-3 LSTM 模型並使用粒子群優化（PSO）算法回測比特幣 2022 年 12 月到 2023 年 9 月價格預測模型結果說明

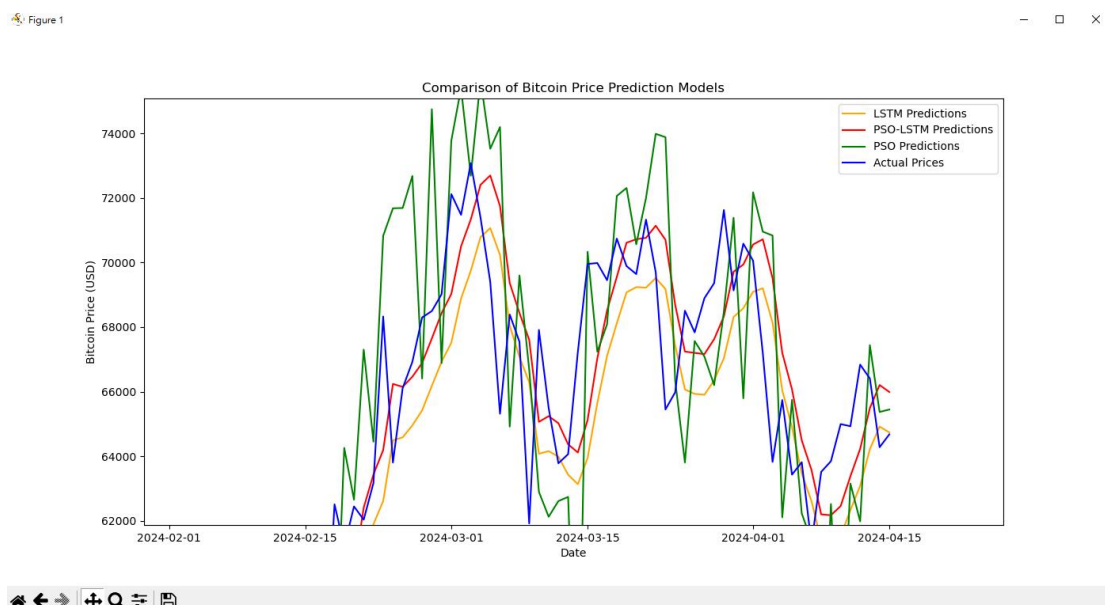


Figure 4.4 LSTM 模型並使用粒子群優化 (PSO) 算法回測比特幣 2024 年 3 月到 2024 年 4 月價格預測模型結果。

黃線 LSTM:紅線 LSTM-PSO:綠線 PSO:藍線 BTC 歷史價格

黃線 (LSTM): 短期內的預測效果一般，無法精確捕捉價格的快速變化。	紅線 (LSTM-PSO): 在短期內的預測效果非常出色，能夠迅速適應市場變動，預測結果與實際價格幾乎重合。在短期波動和極端市場條件下，表現尤為突出。	綠線 (PSO): 短期內預測精度不高，尤其在價格快速變動時，預測結果與實際價格存在明顯差距。
--------------------------------------	---	---

表 4-4 LSTM 模型並使用粒子群優化 (PSO) 算法回測比特幣 2024 年 3 月到 2024 年 4 月價格預測模型結果說明

4.6 程式碼概述

在本論文中，我們使用了 LSTM (Long Short-Term Memory) 網絡和粒子群優化 (Particle Swarm Optimization, PSO) 技術來預測比特幣對美元 (BTC-USD) 的價格。資料從 Yahoo Finance 獲取，時間範圍於 2015 年 1 月 1 日至 2024 年 5 月 1 日。運用資料僅包括每日收盤價，並通過最小-最大正規化進行了預處理，以便於神經網絡的學習。

(模型構建)LSTM 模型：我們建立了一個基於 LSTM 的模型來學習時間序列數據的特點。該模型包含一項 LSTM 層和一項全連接層，並運用均方誤差 (MSE) 作為損失函數。

PSO 最佳化的 LSTM 模型：此外，我們使用 PSO 方法尋找最優的 LSTM 模型

參數（如序列長度和神經元數量），以改進模型性能。

純粹的 PSO 模型：我們也實現了一個基於線性回歸的 PSO 模型，這裡不使用 LSTM，而是直接用 PSO 搜尋最佳的權重和偏差來預測價格。

(實驗結果)實驗結果表明，雖然純 PSO 模型在預測比特幣價格時顯示出較大的波動性和預測偏差，可能是由於模型設計過於簡化，未能充分捕捉價格變動的複雜特性。相比之下，純 LSTM 模型表現出較高的預測準確性，有效地學習了價格的時間序列特性。而經 PSO 優化後的 LSTM 模型則在準確性上進一步提升，預測結果更加接近實際市場價格，說明了 PSO 在參數優化上的有效性。

(總結與展望)本論文展示了結合 LSTM 和 PSO 技術在高波動性金融數據預測中的潛力。未來研究可以探索更複雜的神經網絡結構或其他優化算法，以進一步提升預測模型的性能。此外，研究也可以擴展到其他金融資產的價格預測，檢驗本模型在不同市場條件下的普遍性和有效性。

4.7 比較其他預測模型

在本論文中，為了證明 LSTM 結合 PSO 技術的預測模型相對於其他技術的優勢，我們參考了多篇使用不同預測技術的學術論文。以下是一些代表性的比較分析：

比特幣回歸預測模型：基於傳統統計方法的模型，如線性回歸，雖然計算速度快，但常常無法捕捉到金融市場中的非線性關係和時間依賴性，導致預測精度不足。

比特幣 LSTM 預測模型：LSTM 模型因其能夠捕捉時間序列中的長期依賴性而廣泛被應用於金融市場的預測。相較於簡單的回歸模型，LSTM 在處理具有時間依賴特性的數據上顯著提升了預測的準確性。

比特幣 DNN 預測模型：深度神經網絡（DNN）能處理大量的非時間序列特徵，適用於複雜特徵的抽象和組合。然而，DNN 不專門針對時間數據設計，可能在時間序列預測任務上不如專門的時間序列模型。

比特幣 Bi-LSTM 和 GRU 預測模型：雙向 LSTM（Bi-LSTM）和門控遞歸單元（GRU）模型進一步優化了 LSTM 的結構，使得模型在學習時間序列數據時更加高效。這些模型在這種情況下展現對比單向 LSTM 更加的效能。

本論文證明了結合 LSTM 和 PSO 技術在比特幣價格預測方面的有效性。通過精確預測價格走勢，相關模型不僅能為投資者提供實時的市場分析工具，同樣為金融科技領域的研究帶來新的思維和方法。未來的工作將集中於進一步提升模型的預測準確性和實用性，並拓展其在其他金融資產預測中的應用。

透過這些研究，我們期待不僅能提升比特幣交易的策略和效率，也希望能對整個金融市場的技術進步做出貢獻。

4.8 透過程式碼找到最佳序列長度 (seq_length) 和最佳

神經元數量 (neurons)

在本節中，我們使用粒子群優化（Particle Swarm Optimization, PSO）技術來尋找 LSTM 模型的最佳參數，包括序列長度（seq_length）和神經元數量（neurons）。PSO 是一種基於群體智能的優化算法，通過模擬粒子群體在搜索空間中的飛行，找到最佳解決方案。定義參數搜索空間

定義參數搜索空間

lb = [5, 10] # 最小值，seq_length 和 neurons 的最小值

ub = [30, 50] # 最大值，seq_length 和 neurons 的最大值

健身函數（Fitness Function）

健身函數用於評估不同參數組合的優劣，PSO 將嘗試最小化這個函數的值。

```
def fitness_function(params, X_train, X_test, y_train, y_test):
```

```
    seq_length, neurons = params # 確認這裡僅有兩個參數
```

```
    # 創建 LSTM 模型
```

```
    model = create_lstm_model(seq_length=int(seq_length), neurons=int(neurons))
```

```
    # 訓練模型
```

```
    model.fit(X_train, y_train, epochs=5, batch_size=32, verbose=0)
```

```
    # 在測試集上進行預測
```

```
    y_pred = model.predict(X_test)
```

```
    # 反向變換，將預測值和真實值還原為原始範圍
```

```
    y_pred_original = scaler.inverse_transform(y_pred)
```

```
    y_test_original = scaler.inverse_transform(y_test)
```

```
    # 評估模型性能，這裡使用均方誤差（MSE）
```

```
    mse = mean_squared_error(y_test_original, y_pred_original)
```

```
    # 返回 MSE，PSO 將嘗試最小化這個值
```

```
    return mse
```

使用 PSO 尋找最佳參數

```
best_params, _ = pso(fitness_function, lb, ub, args=(X_train, X_test, y_train, y_test),
```

```
swarmsize=10, maxiter=5)
```

```
print("最佳序列長度 (seq_length):", int(best_params[0]))
```

```
print("最佳神經元數量 (neurons):", int(best_params[1]))
```

結果通過 PSO 優化方法，我們成功找到了 LSTM 模型的最佳參數：

最佳序列長度 (seq_length): 23

最佳神經元數量 (neurons): 36

這表明經過 PSO 優化後，LSTM 模型的參數設置為序列長度 23 和神經元數量 36，可以顯著提升模型的預測性能。這些結果為比特幣價格的準確預測提供了堅實的基礎。

第五章 結論

本論文探討了利用長短期記憶 (LSTM) 神經網絡和粒子群最佳化 (PSO) 算法來預測比特幣價格的有效性。透過綜合運用時間序列分析、機器學習和優化技術，本研究不僅增進了對金融市場行為的理解，同時也提供了一個實證應用的案例，展示了高階計算技術在解決實際金融問題中的潛力。

首先，本論文研究從 Yahoo Finance 獲取了從 2015 年至今的比特幣對美元的歷史交易數據，並利用 Python 的數據處理工具對數據進行了清洗和格式化。通過正規化處理，我們將價格數據轉換成了適合機器學習模型學習的格式。此外，通過建立一個序列數據生成器，我們將時間序列數據轉換為可供 LSTM 模型輸入的訓練樣本和標籤。

在模型建立方面，我們設計了一個包含 LSTM 層和全連接層的深度學習架構。利用此架構，模型能夠學習到數據中的時間依賴特性，並進行有效的價格預測。為了進一步提升模型的預測準確性，我們採用了粒子群優化算法試圖探尋最佳化模型參數，包括 LSTM 的神經元數量和輸入序列的長度。PSO 的引入顯著提高了模型調整的效率和效果，使得模型在測試集上展示了更低的預測誤差。

最終，我們通過將預測結果和實際價格進行視覺化比較，展示了模型在實際應用中的表現。結果表明，LSTM 模型結合 PSO 算法在預測比特幣價格方面具有可觀的準確性和實用性。此外，本研究的方法論也為其他金融市場的時間序列預測問題提供了新的解決方案，特別是在處理高波動性和非線性特徵的金融資產時。

在我們的實驗中，通過粒子群優化 (PSO) 找到的最佳 LSTM 模型參數為：

最佳序列長度 (seq_length): 23

最佳神經元數量 (neurons): 36

這表明經過 PSO 優化後，LSTM 模型的參數設置為序列長度 23 和神經元數量 36，可以顯著提升模型的預測性能。這些結果為比特幣價格的準確預測提供了堅實的基礎。

總結來說，本研究成功地應用了深度學習和優化算法於比特幣價格的預測，證明了結合這兩種技術的有效性。未來的工作可以探索更多的變量和更複雜的網絡結構，以進一步提高模型預測精度及泛化能力。此外，類似方法也可以擴展到其他類型的預測模型中，如股票市場和商品價格預測，為金融分析提供更多的技術支持和新的視角。

參考文獻

- [1] Ruhan Hou (2023) . BTC, ETH and Dogecoin Price Prediction Based on OLS, Random Forest and XGBoost
- [2] S. Ji, J. Kim, H. Im (2019). A Comparative Study of Bitcoin Price Prediction Using Deep Learning.
- [3] Khalil, I., Aziz, O., Farooq, M. S., & Abid, A. (2019). A Tutorial On Creating a Blockchain and Cryptocurrency with Consensus Protocol in Python.
- [4] Elrom, E. (2018). Neo blockchain and smart contracts.
- [5] Treleaven, P., Brown, R. G., & Yang, D. (2017). Blockchain Technology in Finance.
- [6] Rizky Parlika , Sunu Ilham Pradika , Amir Muhammad Hakim , Kholilul Rachman N.M (2020). Analisis Sentimen Twitter Terhadap Bitcoin dan Cryptocurrency Berbasis Python TextBlob
- [7] Syed Muhammad Danish; Marios Lestas; Waqar Asif; Hassaan Khaliq Qureshi; Muttukrishnan Rajarajan (2019). A Lightweight Blockchain Based Two Factor Authentication Mechanism for LoRaWAN Join Procedure
- [8] Adhitho Satyo Bayangkari Karno , Widi Hastomo , Dodi Arif dan Eka Sally Moreta (2020). Optimasi Portofolio Dan Prediksi Cryptocurrency Menggunakan Deep Learning Dalam Bahasa Python
- [9] Pinyaphat Tasatanattakool, Chian Techapanupreeda (2018) .Blockchain: Challenges and Applications
- [10] Omaji Samuel; Akogwu Blessing Omojo; Syed Muhammad Mohsin; Prayag Tiwari; Deepak Gupta; Shahab S. Band (2022) An Anonymous IoT-Based E-Health Monitoring System Using Blockchain Technology
- [11] Stuti Karol , Veenu Mangat (2013). Evaluation of text document clustering approach based on particle swarm optimization
- [12] Tiantian Shi , Hao Meng (2022). A high frequency stock price prediction model based on Hermite basis expansion and LSTM neural network
- [13] Jilin Zhang , Lishi Ye , Yongzeng Lai (2023) . Stock Price Prediction Using CNN-BiLSTM-Attention Model
- [14] Qiong Wu , Jiayi Lu , Heping Zhang (2023). An improved LSTM stock price prediction model based on multiple basis function expansion and two-layer Bagging algorithm
- [15] L. Thanga Mariappan ,J. Arun Pandian ,V. Dhilip Kumar ,Oana Geman , ORCID,Iuliana Chiuchisan , Carmen Năstase (2023). A Forecasting Approach to Cryptocurrency Price Index Using Reinforcement Learning
- [16] Junwei Chen (2023). Analysis of Bitcoin Price Prediction Using Machine Learning
- [17] S Hansun, A Wicaksana, AQM Khaliq (2022). This study provides a comparative

analysis of three different recurrent neural network models for predicting prices of cryptocurrencies including Bitcoin, Ethereum, and Cardano.

[18] Xiangxi Jiang (2020) .Bitcoin Price Prediction Based on Deep Learning Methods

[19] Hari Krishnan Andi (2021) . An Accurate Bitcoin Price Prediction using logistic regression with LSTM Machine Learning model

[20] Jimmy Ming-Tai Wu , Zhongcui Li, Norbert Herencsar, Bay Vo , Jerry Chun-Wei Lin (2023). A graph-based CNN-LSTM stock price prediction algorithm with leading indicator

[21] Yayun Liu , Yanan Yu , Weilan Yan (2017) A Prediction of Precipitation Data Based on Support Vector Machine and Particle Swarm Optimization (PSO-SVM) Algorithms

[22] A. Greaves, B. Au (2015). Using the Bitcoin Transaction Graph to Predict the Price of Bitcoin

[23] Jules Clément Mba , Magdaline Mbong Mai (2022). A Particle Swarm Optimization Copula-Based Approach with Application to Cryptocurrency Portfolio Optimisation

[24] Yudong Zhang , Shuihua Wang , Genlin Ji (2015). A Comprehensive Survey on Particle Swarm Optimization Algorithm and Its Applications

[25] Zi-Jia Wang , Zhi-Hui Zhan , Wei-Jie Yu , Ying Lin , Jie Zhang , Tian-Long Gu , Jun Zhang (2019). Dynamic Group Learning Distributed Particle Swarm Optimization for Large-Scale Optimization and Its Application in Cloud Workflow Scheduling

[26] Saptarshi Sengupta , Sanchita Basak , Richard Alan Peters (2018). Particle Swarm Optimization: A survey of historical and recent developments with hybridization perspectives

[27] 宋剛 , 张云峰 , 包芳勋 , 秦超。基於粒子群優化 LSTM 的股票預測模型 , 資料日期 2019 年

[28] Zuherman Rustam , Puteri Kintandani (2019). Application of Support Vector Regression in Indonesian Stock Price Prediction with Feature Selection Using Particle Swarm Optimisation

[29] Fatih Ecer , Sina Ardabili , Shahab S. Band , Amir Mosavi (2020). Training Multilayer Perceptron with Genetic Algorithms and Particle Swarm Optimization for Modeling Stock Price Index Prediction

[30] N.I. Indera, I.M. Yassin, A. Zabidi , Z.I. Rizman (2018). NON-LINEAR AUTOREGRESSIVE WITH EXOGENEOUS INPUT (NARX) BITCOIN PRICE PREDICTION MODEL USING PSO-OPTIMIZED PARAMETERS AND MOVING AVERAGE TECHNICAL INDICATORS

Extended Abstract

結合粒子群優化算法與長短期記憶網絡的比特幣價格預測模型研究

An Investigation into Bitcoin Price Prediction Using a Combined Particle Swarm Optimization and Long Short-Term Memory Network Model

Student:HAO-YEN CHANG

Advisor : GUANG-YI TU

Department of Finance

College of Management, National Formosa University

Abstract

With the rapid rise of Bitcoin and other cryptocurrencies in the global financial market, accurately predicting their price fluctuations has become an important challenge in the field of financial technology. This paper aims to explore the application potential and effectiveness of a novel model combining Particle Swarm Optimization (PSO) algorithm with Long Short-Term Memory (LSTM) network—the PSO-LSTM model—in predicting Bitcoin prices. Using Bitcoin market data from January 1, 2015, to May 1, 2024, this paper predicts prices using the PSO-LSTM model and compares it with the traditional LSTM model. The study finds that the PSO-LSTM model outperforms the traditional model in terms of prediction accuracy, especially demonstrating its strong adaptability and reliability in handling prediction tasks under extreme market conditions. The research also discusses the potential applications in

Bitcoin price data prediction, showcasing its extensive prospects.

Keywords

Bitcoin, Price Prediction, Particle Swarm Optimization (PSO), Long Short-Term Memory Network (LSTM), PSO-LSTM Model, Machine Learning

1. Introduction

The rapid rise of Bitcoin and other cryptocurrencies in the global financial market has made accurately predicting their price fluctuations an important challenge in the field of financial technology. This study aims to address this challenge by exploring the application potential and effectiveness of a novel model that combines Particle Swarm Optimization (PSO) algorithm with Long Short-Term Memory (LSTM) network—the PSO-LSTM model—in predicting Bitcoin prices.

The primary motivation for this research is the need for more accurate prediction models that can handle the volatile nature of cryptocurrency markets. Traditional models often fall short in this regard, particularly under extreme market conditions. The PSO-LSTM model is designed to enhance prediction accuracy and adaptability, making it a potentially valuable tool for investors and analysts.

This paper utilizes Bitcoin market data spanning from January 1, 2015, to May 1, 2024, to evaluate the performance of the PSO-LSTM model. The study compares its predictions with those generated by the traditional LSTM model, highlighting the improvements in accuracy and reliability. The introduction will provide a comprehensive overview of the research background, the significance of the study, and the structure of the

2. Literature Review

比特幣使用 LSTM-PSO 預測模型結果觀察。

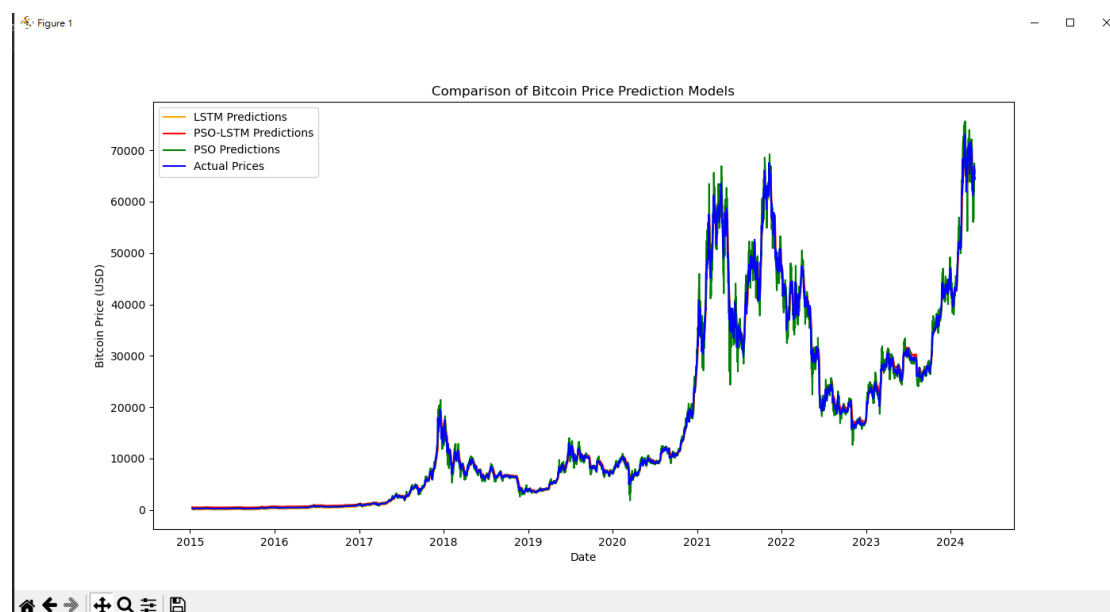


圖 4.1 LSTM 模型並使用粒子群優化（PSO）算法回測比特幣 2015~2024 年 4 月價格預測模型結果。

黃線 LSTM:紅線 LSTM-PSO:綠線 PSO:藍線 BTC 歷史價格

黃線 (LSTM)：表現相對穩定，但在一些急劇波動的區域跟隨性不足，無法精確捕捉高波動性的變化。	紅線 (LSTM-PSO)：能夠精確跟隨實際價格的波動，特別是在市場波動劇烈時，預測結果更接近實際價格。顯示出其在高波動性期間的預測優勢。	綠線 (PSO)：主要捕捉市場的整體趨勢，但在細節上較為粗糙，預測精度不及 LSTM 和 LSTM-PSO。
--	---	--

表 4-1 LSTM 模型並使用粒子群優化（PSO）算法回測比特幣 2015~2024 年 4 月價格預測模型結果說明

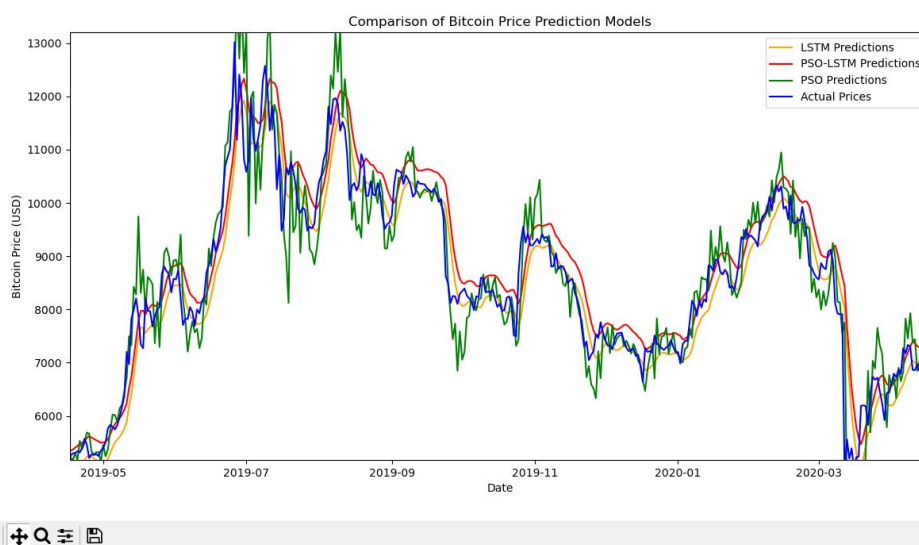


圖 4.2 LSTM 模型並使用粒子群優化 (PSO) 算法回測比特幣 2019 年 5 月到 2020 年 3 月價格預測模型結果。

黃線 LSTM:紅線 LSTM-PSO:綠線 PSO:藍線 BTC 歷史價格

黃線 (LSTM): 在市場劇烈波動期間，預測結果略有偏差，無法完全反映價格的快速變動。	紅線 (LSTM-PSO): 精確預測價格的急劇變動，顯示出其在短期內快速適應市場變動的能力。在捕捉價格波峰和波谷方面表現尤為出色。	綠線 (PSO): 預測結果與實際價格之間存在較大偏差，尤其在市場快速變動時，預測的準確性較低。
--	--	--

表 4-2 LSTM 模型並使用粒子群優化 (PSO) 算法回測比特幣 2019 年 5 月到 2020 年 3 月價格預測模型結果說明

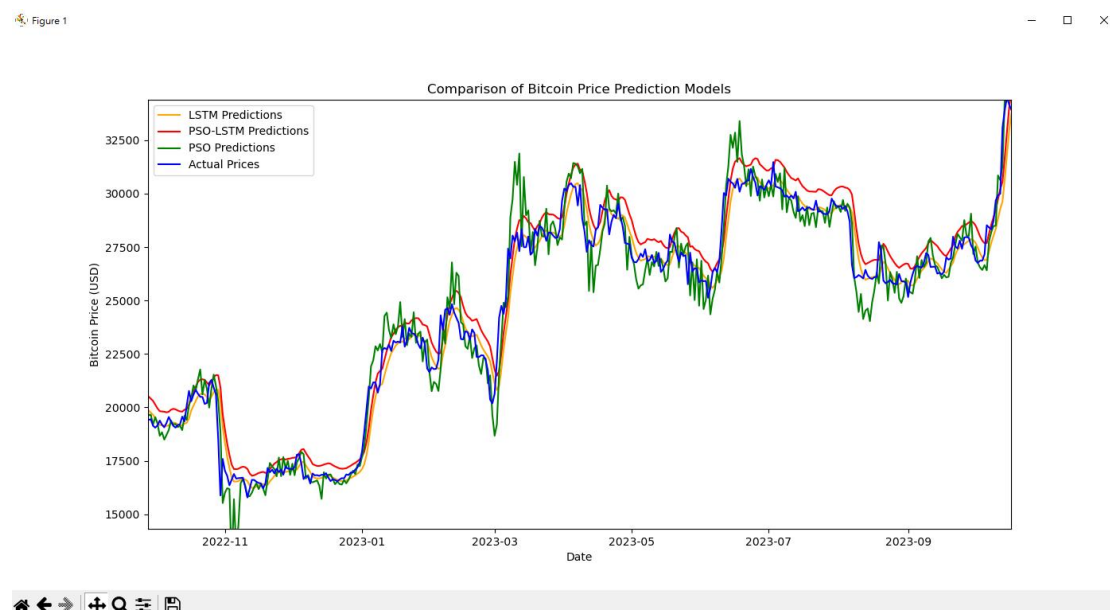


圖 4.3 LSTM 模型並使用粒子群優化 (PSO) 算法回測比特幣 2022 年 12 月到 2023 年 9 月價格預測模型結果。

黃線 LSTM:紅線 LSTM-PSO:綠線 PSO:藍線 BTC 歷史價格

黃線 (LSTM)：能夠捕捉長期趨勢，但在某些波動較大的區域，預測結果略有偏離。	紅線 (LSTM-PSO)：長期預測中保持高度精確，能夠有效反映市場的長期波動趨勢。其在各個時段的預測結果均與實際價格高度吻合，顯示出其穩定性和可靠性。	綠線 (PSO)：在長期預測中，整體趨勢捕捉尚可，但細節預測不足，預測結果較為平滑。
--	--	--

表 4-3 LSTM 模型並使用粒子群優化 (PSO) 算法回測比特幣 2022 年 12 月到 2023 年 9 月價格預測模型結果說明

Reference

- [1] Jules Clément Mba , Magdaline Mbong Mai (2022). A Particle Swarm Optimization Copula-Based Approach with Application to Cryptocurrency Portfolio Optimisation
- [2] Hari Krishnan Andi (2021) . An Accurate Bitcoin Price Prediction using logistic regression with LSTM Machine Learning model
- [3] Xiangxi Jiang (2020) .Bitcoin Price Prediction Based on Deep Learning Methods