

國立屏東大學資訊學院資訊管理學系

碩士論文

Department of Information Management, College of Computer Science

National Pingtung University

Master Thesis

時間序列套件及基於預處理的深度學習模型  
在加密貨幣價格預測之績效比較

**Performance Comparison of Time Series  
Packages and Preprocessed Deep Learning  
Models in Predicting Cryptocurrency Prices**

邱智清 撰

by Zhi-Qing Qiu

指導教授：蕭文峰 博士

Advisor: Wen-Feng Hsiao, Ph.D.

中華民國 113 年 2 月

February 2024

國立屏東大學資訊管理學系碩士班

碩士論文

研究生：邱智清

論文題目

時間序列套件及基於預處理的深度學習模型  
在加密貨幣價格預測之績效比較

本論文經審查及口試合格特此證明

論文口試委員會主席

張 悅 民

委員

蕭 文 峰

委員

王 志 雄

指導教授：蕭文峰 博士

蕭 文 峰

系主任：李來錫 博士

李 來 錫

中 華 民 國 113 年 1 月 31 日

## 致謝

非常感謝指導教授蕭文峰老師，在就讀期間教導我許多關於程式方面及論文撰寫的方式。雖然撰寫論文時有許多描述不好的地方，是我本身的短處，但是老師還是非常有耐心的教導我撰寫論文，讓我能順利通過論文口試，並讓我順利畢業。

也感謝中山大學資管系張德民老師以及本校企管系王志雄老師擔任口試委員，在口試時給我許多論文建議，使論文能更加的完整。

也特別感謝碩士班的同學們，瑋佑及柏燊，在研究所期間課業上的幫助。最後非常感謝我的家人，鼓勵並支持我就讀研究所，在就讀期間也給予我許多建議，順利取得碩士學位。

邱智清 謹誌

于 國立屏東大學 資訊管理學系研究所

中華民國一一三年一月

## 摘要

傳統時間序列預測是金融市場預測的主要方法，但隨著深度學習技術的發展，深度學習模型在預測金融市場中的應用也日益廣泛。由於市場對更有效的預測需求持續增加，許多相關的套件和模型也在不斷開發和改進。如何有效和正確地使用這些套件和模型，已成為了一個重要的問題。

本研究比較了套件和基於前處理的深度學習模型在預測加密貨幣的表現。結果顯示，傳統的時間序列方法(ARIMA)透過套件選擇最佳模型參數，仍舊出現過度擬合現象。在 Weka 時間序列套件方面，基礎學習器為 Holt-Winters 各方面表現都優其他機器演算法，而學習器為隨機森林時，也有出現過度擬合。Prophet 的初始誤差較大，但經過加入前七期收盤價作為回歸變數和自定義季節性後，表現有所提升。在深度學習方面，對資料進行對數轉換和標準化處理後，再訓練 CNN、LSTM 等模型，準確率明顯提升。

在加密貨幣市場中，前期資料的代表性對模型的預測準確度有較大影響，因為加密貨幣推廣初期普及程度較低，所以價格波動較小，剔除前期資料可以有效提升模型準確率。加密貨幣市場波動迅速，因此資料頻率的選擇至關重要。本研究中使用每日、每小時資料，用於套件、深度學習模型的建立。結果表明經過預處理的深度學習模型準確度高，而套件在使用適當參數進行預測時，也可以取得不錯的結果，甚至超越深度學習。

關鍵詞：時間序列預測、深度學習、加密貨幣

## Abstract

Traditional timeseries forecasting is the main method for financial market forecasting. However, with the development of deep learning techniques, deep learning models are increasingly being used in financial market forecasting. Many related packages and models are being developed and improved. How to effectively and correctly use these packages and models has become an important issue.

This study compares packages and deep learning models based on preprocessing for forecasting cryptocurrency performance. The results show that the traditional timeseries method (ARIMA) still exhibits overfitting even when the best model parameters are selected through the package. In the Weka timeseries package, Holt-Winters outperforms other machine algorithms in all aspects. However, when the learner is a RandomForest, overfitting also occurs. Prophet's initial error is relatively large, but after adding the previous seven closing prices as regressors variables and customizing seasonality, the performance improves. For deep learning, by applying a logarithmic transformation to the dataset followed by z-score normalization, we've observed a notable improvement in the performance metrics, specifically MAE and RMSE, of various models including CNN and LSTM.

The representativeness of historical data has a significant impact on the prediction accuracy of the model. Given the initially low popularity of cryptocurrencies during their early promotion phases, excluding certain historical data can significantly enhance model accuracy. The cryptocurrency market is volatile, so the choice of data frequency is crucial. In this study, daily and hourly data are used for the establishment of packages and deep learning models. The results show that the deep learning model with preprocessing has high accuracy, and the package can also achieve good results when using appropriate parameters for prediction, even surpassing deep learning.

Keywords: Timeseries Forecasting, Deep Learning, Cryptocurrency

## 目錄

致謝 .....	i
摘要 .....	ii
Abstract .....	iii
圖目錄 .....	v
表目錄 .....	vi
壹、 緒論 .....	1
一、 研究背景 .....	1
二、 研究動機 .....	2
三、 研究目的 .....	2
貳、 文獻探討 .....	3
一、 時間序列分析 .....	3
二、 Weka 時間序列預測 .....	4
三、 深度學習模型 .....	4
四、 時間序列套件 .....	6
五、 加密貨幣 .....	6
參、 研究方法 .....	9
一、 資料蒐集 .....	9
二、 模型選擇 .....	11
三、 模型參數設定 .....	12
四、 評估模型 .....	17
肆、 研究結果 .....	19
一、 時間序列分解 .....	19
二、 基線模型(ARIMA) .....	23
三、 時間序列預測套件(Weka、Prophet)實驗結果 .....	24
四、 深度學習模型(LSTM、BiLSTM、CNN、LSTM+CNN)實驗結果 .....	27
五、 實驗結果小結 .....	29

伍、 結論 .....	32
參考文獻 .....	33
附錄 A.....	37
附錄 B.....	44

## 圖目錄

圖 1. 研究流程圖 .....	9
圖 2. ARIMA 建立模型流程圖 .....	13
圖 3. LSTM 架構圖 .....	18
圖 4. BiLSTM 架構圖.....	18
圖 5. CNN 架構圖 .....	18
圖 6. CNN+LSTM 架構圖 .....	18
圖 7.比特幣全部區間相加模型 .....	19
圖 8.比特幣全部區間相乘模型 .....	20
圖 9. 比特幣每小時區間相加模型 .....	21
圖 10.比特幣每小時區間相乘模型 .....	22

## 表目錄

表 1. 近來深度學習用於預測加密貨幣的研究比較表 .....	8
表 2. 本研究所採用的加密貨幣及其基本資料 .....	10
表 3. 不同加密貨幣移除部份區間後之比較表 .....	11
表 4. 本研究所使用模型與其所屬之套件 .....	12
表 5. 資料集最佳 ARIMA(p,d,q)模型 .....	14
表 6. Weka timeseriesForecasting 套件設定值 .....	14
表 7. Holt-Winters 平滑因子設定值 .....	15
表 8. Prophet 套件設定值 .....	15
表 9. keras-tuner (LSTM)探索最佳參數 .....	16
表 10. keras-tuner (BiLSTM)探索最佳參數 .....	16
表 11. keras-tuner (CNN)探索最佳參數 .....	17
表 12. keras-tuner (CNN+LSTM)探索最佳參數 .....	17
表 13. 比特幣之 ARIMA 模型績效 .....	23
表 14. 以太幣之 ARIMA 模型績效 .....	23
表 15. 幣安幣之 ARIMA 模型績效 .....	24
表 16. 泰達幣之 ARIMA 模型績效 .....	24
表 17. 全部區間加密貨幣在套件模型績效 .....	25
表 18. 去除兩年區間加密貨幣在套件模型績效 .....	25
表 19. 去除四年區間加密貨幣在套件模型績效 .....	26
表 20. 每小時區間加密貨幣在套件模型績效 .....	26
表 21. 深度學習模型在比特幣上的績效 .....	27
表 22. 深度學習模型在以太幣上的績效 .....	28
表 23. 深度學習模型在幣安幣上的績效 .....	28
表 24. 深度學習模型在泰達幣上的績效 .....	29



表 25. 比特幣全部區間與去除四年區間模型績效比較摘要表 .....	30
表 26. 以太幣全部區間與去除四年區間模型績效比較摘要表 .....	30
表 27. 幣安幣全部區間與去除四年區間模型績效比較摘要表 .....	31
表 28. 泰達幣全部區間與去除四年區間模型績效比較摘要表 .....	31

## 壹、緒論

### 一、研究背景

時間序列預測是金融市場預測中一種重要和常用的方法，廣泛應用於股票、外匯、期貨等金融市場，以及近年來興起的數位貨幣市場(e.g.[6][4][15][29])。時間序列預測倚賴過去價格數據和模式的研究，以便預測未來價格走勢。然而，隨著深度學習技術的不斷進步，例如長短期記憶 (LSTM)、門控遞歸單元 (GRU) 等神經網路結構的日益普及，深度學習在金融市場中的應用也變得更為廣泛。深度學習模型具備處理非線性關係和大量數據的能力，因此能夠提供更為準確的預測。值得一提的是，因為市場對更有效的預測需求持續增加，許多相關的套件和模型也在不斷開發和改進，以支持這一領域的進一步發展，而如何正確使用模型與套件也是一大難題。

時間序列預測(time series forecasting)是具有相當挑戰性的研究主題，吸引了大量學界與業界人士的投入與關注。傳統的統計和機器學習方法已經在許多領域得到不錯的成果，結合深度學習技術時間序列預測的效果得到了進一步的提升。然而，要持續跟上這些技術的最新進展並不容易。近年來，多種新的時間序列預測方法不斷出現，如 Facebook 的 Prophet、基於深度學習的不同模型(e.g. [4][5][13][19])。本研究探討不同方法在加密貨幣資料的預測上表現如何。

Weka 是一套著名的資料探勘工具，提供了一系列強大的機器學習演算法，過去已被廣泛應用於資料分析和建立預測模型(e.g.[2][5][19])。Weka 亦提供時間序列預測的套件，透過整合的圖形化界面，初學者能輕鬆進行時間序列資料的預測與評估。但對於熟悉機器學習專業人員在某些進階功能或客製化的需求上，其彈性仍有不足。為了彌補這一不足，Weka 亦提供 API 界面供 Java, Python、及 R 的程式開發者使用。

各種套件的開發都反映了時間序列預測在不同領域中都共同存在需求。需求跨足金融業、旅遊業、環境變數等多個領域，甚至包括 COVID-19 等重要議題

(e.g. [3][11][24][29])。這些套件的開發不僅為相關領域的進步提供了有力支持，也突顯了時間序列預測在解決各種實際挑戰中的關鍵作用。

## 二、研究動機

除了前述的套件之外，時間序列預測領域廣泛應用了許多其他套件。Siebert 等人([28]) 經過對 40 種與時間序列相關的 Python 套件進行性能和功能評估後，發現這些套件中預測功能最為常見，其中包含 pmdarima、prophet 等都是用於預測的套件，也顯示時間序列預測的套件種類不少，初入研究領域的研究人員可以參考，而在加密貨幣市場中該選擇哪一種套件，是前述研究中未提及的。

資料集的代表性對預測模型的性能起著至關重要的作用，例如需要預測股市走向，資料集只採用市場價值進行預測走勢，並不是良好的資料集。即使數據量充足，並且資料集代表性得到了保證，資料採集的頻率也會對預測結果產生不同程度的影響。此外，資料集代表性也在一定程度上影響了工具套件的使用效果。確保代表性和採集頻率與研究需求相符，以及選擇合適的工具和套件，對於建立準確的預測模型至關重要。

## 三、研究目的

基於上述研究動機，本研究之研究目的如下：

- (一) 比較時間區間在加密貨幣市場預測中的準確度。
- (二) 比較不同加密貨幣在套件和深度學習模型的準確度。
- (三) 探討加密貨幣市場資料採集頻率適用於套件或深度學習模型。

## 貳、文獻探討

### 一、時間序列分析

時間序列是一系列按時間順序排列的資料，可以用於分析不同時間範圍內的趨勢，例如股票價格、氣象資料和交通流量等(e.g.[3][6])。時間序列分析中，主要對時間序列資料進行分析，以了解其結構和特徵，欲突顯長期趨勢可以使用移動平均法，隔離季節性成分可使用加法模型或乘法模型調整等技術，解決雜訊成份則可以使用異常值檢測或穩健迴歸等方法。時間序列分析通常分為三個主要組成部分([22]):趨勢(trend)、季節性(seasonality)和雜訊(noise)(或稱為殘差 residual)。一些學者提議還有第四部分，即週期性(cyclical)，但由於與趨勢容易混淆，一般研究者通常不對其進行特別處理(leave it alone)。

時間序列預測是透過統計或機器學習方法，會嘗試建立時間序列資料的模型，以便針對未來時間點進行預測。典型的時間序列資料預測模型包括自迴歸綜合移動平均(AutoRegressive Integrated Moving Average, ARIMA)和指數平滑(Exponential Smoothing, ES)。指數平滑則是基於加權平均進行預測，其中每個觀測值的重要性會隨時間遞減。當需要處理趨勢時，有「雙指數平滑(double exponential smoothing)」或「三重指數平滑法(triple exponential smoothing 又稱 Holt-Winters)」，是時間序列分析模型，捕捉時間序列中的趨勢、季節性和殘差。方法常用於時間序列分析，廣泛應用於多個統計軟體或套件。

ARIMA 是一種廣泛應用於時間序列預測的統計方法([22])，結合了自迴歸(AR)和移動平均(MA)的概念，並包括一個整合(I)的步驟，用於處理非平穩(non-stationary)時間序列數據，模型在 1960 年代首次提出，並在 1970 年代得到了廣泛的應用。其主要目標是捕捉時間序列中的趨勢、季節性變化以及隨機殘差，以實現對未來數據的預測。優點是簡單易用，適用於各種時間序列資料，具有良好的預測性能。而對於資料要求較高，並且容易出現過度擬合(overfitting)的問題。因此，通常會視為基線模型，並與其他更高級的時間序列預測方法進行

比較，以找到最適合特定數據的模型。當然 ARIMA 也有許多應用於此的套件如 statsmodels、pmdarima 等，研究者可根據資料特性選擇適合的套件。

## 二、Weka 時間序列預測

Weka 是一個由紐西蘭 Waikato 大學開發的開放原始碼(open source)資料探勘工具，包含一系列用於資料分析和預測建模的機器學習演算法。Weka 支援多種標準資料探勘任務，包括資料預處理、分群(clustering)、分類(classification)、迴歸(regression)、關聯規則分析(association rule analysis)、視覺化(visualization)和特徵選擇(feature selection)。進階的探勘亦支援時間序列預測、資料串流探勘、以 Apache SPARK 進行分散式處理等。不過，Weka 的整合圖形用戶界面操作簡便，但對於需要圖像處理、深度學習模型或時間序列預測的任務，則需安裝其提供的額外套件方能實現。

python-weka-wrapper 套件提供 python 使用者可以輕鬆地在 Python 中呼叫 Weka 演算法和過濾器。它使用 python-javabridge 套件(使用圍繞 JNI 呼叫的精簡包裝器)來存取 Weka 的 API。使得使用者可以在熟悉的程式環境中工作時，利用 Weka 提供的強大的機器學習演算法和資料分析工具。透過 API 的呼叫使用者可以呼叫 Weka 的內建功能進行資料的預處理、方法的選擇、參數的設定、預測的步數、及模型的評估。至於在圖表的繪製及額外的分析則可透過其它套件來加以輔助完成，例如 matplotlib、pandas 及 scikit-learning 等工具來完成。

## 三、深度學習模型

近年來由於圖形處理單元(GPU)的平行處理能力大大減少訓練深度學習模型所需的時間([2])，因此深度學習算法也逐漸廣泛地應用於時間序列的預測任務上([13])。在深度學習模型中，遞歸神經網路(RNN)，尤其是長短期記憶(LSTM)([9])網路和卷積神經網路(CNN)已被證明是時間序列預測的強大工具。

LSTM 和 BiLSTM 都是循環神經網路的一種，它們特別適合處理序列資

料。BiLSTM 代表「雙向長短期記憶」。這兩個模型可以降低梯度消失<sup>1</sup>和梯度爆炸<sup>2</sup>的問題，使得它們在處理長時間序列資料時更有優勢([21])。

CNN 是一種深度學習的神經網路模型，在圖像處理、語音識別、自然語言處理等領域具有廣泛的應用([32])。時間序列中的數據通常具有局部相似性，例如股價的短期趨勢、天氣的短期變化等。可以通過卷積層，提取時間序列中相鄰數據之間的局部特徵，從而為預測提供更豐富的訊息([8])。深度學習模型比機器學習模型具有更複雜的結構，導致訓練時間更長，但預測更準確、更穩健。TensorFlow 和 PyTorch 等高級程式庫使深度學習模型的實施和實驗變得更加容易。TensorFlow 是一個開源的機器學習和人工智慧套件庫。PyTorch 同樣是一種開放原始碼的 Python 深度學習框架，適用於各種人工智慧領域，包括電腦視覺、自然語言處理等。兩者都可以用來構建和訓練各種深度學習模型。通過整合資訊，深度學習模型可以獲得更廣泛的數據，從而提高其性能。

深度學習模型的優點包括處理遺失值的能力、捕獲複雜樣式、自動學習特徵、可擴展性和端到端訓練([7])。然而，深度學習模型也面臨著一系列挑戰，例如需要大量資料才能有效訓練、過度擬合的風險以及更高的計算成本。深度學習和統計方法的選擇應基於問題的特性、資料的特徵、可用的資源及領域知識來決定。

近年來，研究並開發金融時間序列的深度學習模型一直是學者關注的焦點，並廣泛評估各種技術和指標的適用性([34])。當然，一些學者專注於發展高效的預測深度學習模型，在模型性能方面也取得卓越的成就(e.g.[12][32][33])。當談到加密貨幣市場時，無疑是更是業界研究的目標，尤其是在應用深度學習技術以建立更精確預測模型方面(e.g.[23][21])。學者針對不同深度學習模型在加密貨幣上進行比較，研究比較 RNN、LSTM、BiLSTM 與 CNN+LSTM 等不同模型，結果顯示 CNN+LSTM 模型表現最好，其次為 BiLSTM 模型，CNN+LSTM 可以結合

---

<sup>1</sup> 梯度消失是指梯度在反向傳播過程中逐漸變小，直到變得趨近於 0。

<sup>2</sup> 梯度爆炸是指梯度在反向傳播過程中逐漸變大，甚至趨近於無窮大。

兩者的優勢，在序列數據處理方面具有較好的效果([7])。

#### 四、時間序列套件

Prophet 是由 Facebook 核心資料科學團隊所開發(開發者為 Taylor and Letham)的開放原始碼的程式庫，適用於單變量(univariate)的時間序列預測([30])。它預設以相加模型進行訓練，支援趨勢、季節性和假日影響，提供 R 和 Python 的 API。自發行後已成為受歡迎的預測工具之一，可完全自動化或手動調整。可調參數包括季節性類型(加法或乘法)、變化點敏感度、變化點歷史比例、假期參數強度等。選擇定義季節性的參數可以是線性或邏輯斯諦增長，控制季節性的靈活性。這些設定允許模型適應不同資料的本質，讓初學者和專家都能有效使用，並提供對季節的複雜性進行建模的彈性。

還有其他套件如 sktime、PyFlux、PyCaret 等，以及許多先前的研究者已根據不同的分析任務和預處理方法，將各種大小不同的時間序列套件進行分類，並提供了有關這些套件的開發特徵的資訊([10])。套件常用於市場營銷、廣告、金融等領域(e.g. [4][6])，也有研究者使用於社會環境中(e.g. [3])。然而，本研究主要關注點在於套件應用於加密貨幣中的績效表現。

#### 五、加密貨幣

加密貨幣是一種基於密碼學技術，並由網路中的節點共同維護的數位資產。與傳統法定貨幣不同，不受中央機構的控制，具有去中心化、安全性和透明性等優點。由於其去中心化的特性，加密貨幣的價格波動較大，且在一些國家和地區仍不具備合法地位。儘管如此，加密貨幣已成為一種全球性的現象，並逐漸得到越來越多人的認可。根據市值、知名度和成交量等因素，市面上已有各式各樣並且功能不同的加密貨幣，如比特幣、以太幣等等。

比特幣是加密貨幣市場中最著名的貨幣，也是第一種加密貨幣。它於 2009 年由匿名人士中本聰(Satoshi Nakamoto)創建。比特幣的成功催生了全球社群、數百萬家企業和數千個類似計畫。比特幣的出現改變了人們對貨幣的看法，也為區

塊鏈技術的發展奠定了基礎(e.g. [1][23][21])。

以太坊是一種去中心化的開源區塊鏈平台，也是一種分散式應用程式 (DApp) 的平台，擁有自己的加密貨幣「以太幣 (Ether)」。以太坊的目標是創造一種更通用的去中心化平台，可用於開發各種 DApp。其優勢之一是智能合約功能，可自動執行特定條件下的交易。以太坊的成功表明去中心化應用程式具有廣闊的應用前景。幣安幣 (BNB)，是一種功能型代幣，由幣安交易所(現今第一大交易所)發行。幣安幣是幣安生態系統的功能型代幣，可用於支付手續費、參與幣安資產發行平台 (LaunchPad) 上的代幣銷售、交易其他加密貨幣(包括比特幣和以太幣)和使用幣安去中心化交易所。

穩定幣是除了主流幣之外的另一種加密貨幣，其價值穩定，通常與美元或黃金掛鉤。泰達幣 (USDT) 是一種以美元為錨定的穩定幣，於 2014 年推出，旨在為加密貨幣市場提供穩定的價值。泰達幣的發行機構 Tether Limited 承諾以美元儲備為泰達幣的價值提供 1:1 的支持。泰達幣是全球最受歡迎的穩定幣之一，也是加密貨幣交易所中最常用的支付方式之一。

不少研究採用不同加密貨幣進行模型之間比較，像是 Alonso-Monsalve 等人([1])專注在高頻率資料模型間的對比，研究顯示 CNN 表現最優尤其是在比特幣、以太幣等貨幣上。Fan 等人([7])專注在比較深度學習模型間的準確度，研究顯示 CNN-LSTM 模型表現最佳，也表示遠遠超過傳統時間序列模型。Goutte 等人([8])專注在經濟指標如何採用才能建立最佳模型，研究說明使用基本價格(最高價、最低價、開盤價、市場價值)所建立的 LSTM 最佳。些許研究人員專注在深度學習模型的開法，如 P 等人([21])提出 BiLSTM 就比線性迴歸與 XGBoost 提供了更好的預測。



表 1. 近來深度學習用於預測加密貨幣的研究比較表

論文	比較貨幣	使用方法	資料區間	資料 頻率	最佳 模型
[1]	比特幣 達世幣 以太幣 萊特幣 門羅幣 瑞波幣	CNN、 CNN-LSTM、 多層感知器、BFNNs	2018/7 至 2019/6	每分鐘	CNN
[7]	比特幣 以太幣 幣安幣	RNN、LSTM、GRU、 BiLSTM、CNN-LSTM	2017/11 至 2022/8	每日	CNN- LSTM
[8]	比特幣	Logistic 迴歸、 XGBoost、LightGBM、 MLP、GRU、LSTM、 CNN	2017 至 2022	每小時	LSTM
[21]	比特幣	BiLSTM、 線性迴歸、XGBoost	2012/1 至 2020/9	每分鐘	BiLSTM

## 參、研究方法

本研究旨在評估不同套件在加密貨幣市場中的預測性能，根據傳統時間序列模型、時間序列預測套件和深度學習模型的特性，對數據進行預處理，並根據模型調整設定值。完成模型建立後，進行模型性能比較分析。




圖 1. 研究流程圖

### 一、資料蒐集

#### (一) 加密貨幣種類

本研究以當前主流幣（比特幣、以太幣、幣安幣）為主要目標，透過 Yahoo! Finance 的 API 取得資料。此外，考慮到泰達幣的穩定性特性和價格浮動較小的特點，作為輔助觀測貨幣，以觀測模型是否建立完整。

#### (二) 資料獲取週期

由於加密貨幣市場的波動性高，較舊的資料或以天為週期的資料可能無法反映當前市場趨勢。過往研究多使用以天為週期的資料，並加入多個指標作為特徵值，因此難以比較模型的效果。本研究以單一特徵值(收盤價)作為目標，以利後續研究的比較。本研究使用兩種不同週期加密貨幣資料，以比較其中的差異。由於加密貨幣是 24 小時交易，因此其 K 線開盤價和收盤價的計算依據線圖的時間單位（在交易所的頁面中，通常有每分鐘、每八小時、每日等不同時間頻率），以特定時間為基準。例如，日資料的開盤價為午夜 12 點，收盤價為 23 點 59 分。

本研究使用每日週期與每小時週期的加密貨幣資料，包括比特幣（BTC）、以太幣（ETH）、泰達幣（USDT）和幣安幣（BNB），單位皆以美元記錄。由於比特幣最早的公開交易日期為 2009/01/12，但 Yahoo 的公開 API 所能獲取的最早日期為 2014/09/17，因此本研究的比特幣資料區間涵蓋 2014/09/17 至 2023/11/30。

表 2. 本研究所採用的加密貨幣及其基本資料

加密貨幣	每日週期	資料筆數	檔案大小
比特幣	2014/09/17~2023/11/30	3362	339KB
以太幣	2017/11/09~2023/11/30	2213	244KB
泰達幣	2017/11/09~2023/11/30	2213	255KB
幣安幣	2017/11/09~2023/11/30	2213	246KB
加密貨幣	每小時週期	資料筆數	檔案大小
比特幣	2023/11/01~2023/11/30	720	71KB
以太幣	2023/11/01~2023/11/30	720	84KB
泰達幣	2023/11/01~2023/11/30	720	88KB
幣安幣	2023/11/01~2023/11/30	720	86KB

### (三) 資料區間

加密貨幣創建初期，價格走勢較為平坦，主要是因為當時的知名度較低，只有少數投資者和早期使用者參與，因此價格波動較小。隨著逐漸普及，越來越多投資者和使用者參與，市場的流動性增加，價格波動也隨之加大。此外，加密貨幣市場的變動性較高，受到多種因素的影響，包括技術發展、政策變化、市場情緒等，因此舊有資料可能無法反映當前市場趨勢。結合上述本研究採用三種不同的資料區間：全部區間、去除兩年區間和去除四年區間。

表 3. 不同加密貨幣移除部份區間後之比較表

加密貨幣	全部區間	資料筆數	檔案大小
比特幣	2014/09/17~2023/11/30	3362	339KB
以太幣	2017/11/09~2023/11/30	2213	244 KB
泰達幣	2017/11/09~2023/11/30	2213	255 KB
幣安幣	2017/11/09~2023/11/30	2213	246 KB
加密貨幣	去除兩年區間	資料筆數	檔案大小
比特幣	2016/09/17~2023/11/30	2631	259 KB
以太幣	2019/11/09~2023/11/30	1483	163 KB
泰達幣	2019/11/09~2023/11/30	1483	171 KB
幣安幣	2019/11/09~2023/11/30	1483	165 KB
加密貨幣	去除四年區間	資料筆數	檔案大小
比特幣	2018/09/17~2023/11/30	1901	185 KB
以太幣	2021/11/09~2023/11/30	752	83 KB
泰達幣	2021/11/09~2023/11/30	752	87 KB
幣安幣	2021/11/09~2023/11/30	752	84 KB

## 二、模型選擇

本研究運用四種套件(pmdarima、Weka、Facebook Prophet、TensorFlow)構建時間序列模型，其中包括時間序列模型（ARIMA、Holt-Winters）、深度學習模型（CNN、LSTM、CNN+LSTM、BiLSTM、Prophet）以及其他機器學習算法（隨機森林、線性回歸、SVM 迴歸）做為比較模型。表 4 為本研究所使用模型與其對應套件及簡介：

表 4. 本研究所使用模型與其所屬之套件

模型	簡介	使用套件
ARIMA	傳統用於分析時間序列的模型。	pmdarima
線性迴歸	基於線性關係假設。	Weka
SVM 迴歸	一種能捕捉非線性模式的先進方法。	Weka
隨機森林	一種集成方法，可對複雜關係進行建模。	Weka
Holt-Winters	專為時間序列預測設計的方法。	Weka
Prophet	強大的處理季節性和假期工具。	Facebook Prophet
LSTM	序列數據中捕捉長短期依賴關係的神經網路。	TensorFlow
BiLSTM	雙向循環神經網路，同時捕捉序列數據的前後依賴關係。	TensorFlow
CNN	借助卷積運算，可提取局部特徵的神經網路。	TensorFlow
CNN+LSTM	結合卷積和循環神經網路，捕捉序列數據中的局部和長短期依賴關係的神經網路。	TensorFlow

### 三、模型參數設定

#### (一) pmdarima 套件(ARIMA)設定

ARIMA(p,d,q)模型在建立之前，首先需要檢查時間序列是否呈現非平穩性，如果時間序列呈現非平穩性，則需要進行差分操作，差分操作的次數為整合階數(d)。隨後，需要針對模型 AR 的階數 p 與 MA 的階數 q 進行參數估計，列出所有可能的 p 和 q 值，並組成排列組合後，針對每個排列組合 ARMA(p,q)模型進行擬合，並計算 AIC 值。選擇 AIC 值最低的模型進行殘差分析，若殘差分析未通過，則選擇 AIC 值次低的模型。就可以使用 ARIMA 模型進行時間序列的預測，完整流程如圖 2。

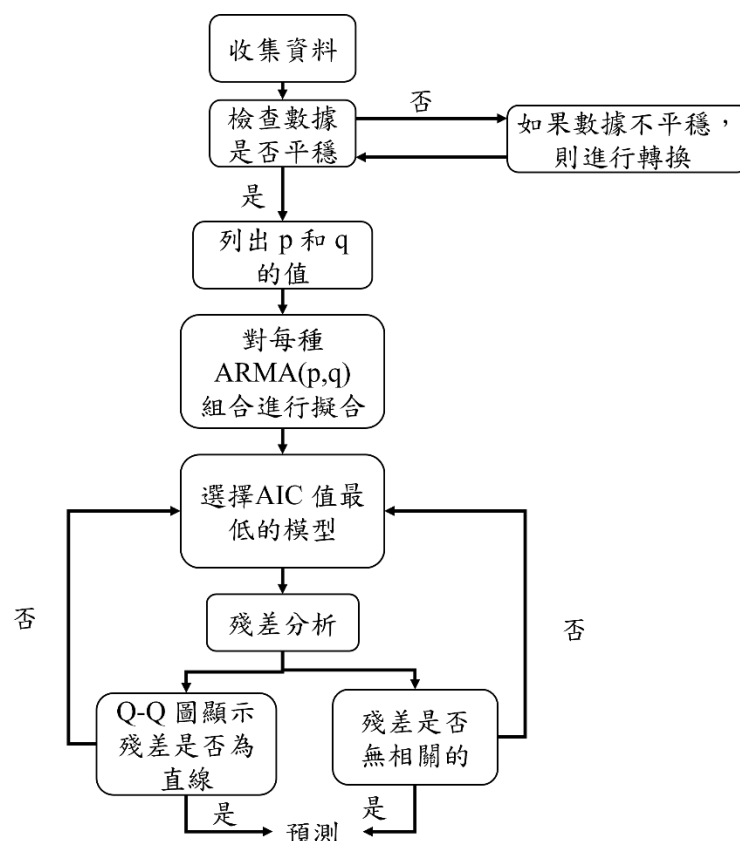


圖 2.ARIMA 建立模型流程圖

修改自：Peixeiro, M. (2022). Time Series Forecasting in Python. Manning Publications.

由於 ARIMA 模型的參數數目眾多，且參數之間存在相互制約關係，因此手動建立 ARIMA 模型的難度較高，並且會花費許多時間。因此，本研究使用 pmdarima 套件來自動尋找最佳模型。它支持多種 ARIMA 模型，並提供了自動調參功能。此外，pmdarima 還支持多種模型評估指標，如 AIC、BIC 等，可以幫助選擇最優模型。設定參數 p 和 d 的最大值設為 20，以便 pmdarima 套件有足夠的空間來尋找最佳模型。本研究針對全部區間、去除兩年區間與去除四年區間加入前 7 期的值作為外生變數(exogenous)<sup>3</sup>，而每小時區間則採用前 12 的值，表 5 為透過套件獲取資料集最佳模型。

<sup>3</sup> 外生變量是指對時間序列數據的趨勢和變化有影響的因素

表 5. 資料集最佳 ARIMA(p,d,q)模型

資料集	最佳模型			
	比特幣	以太幣	幣安幣	泰達幣
全 部 區 間	ARIMA(6,2,4)	ARIMA(2,1,3)	ARIMA(4,1,2)	ARIMA(4,1,2)
去除兩年區間	ARIMA(2,1,2)	ARIMA(1,1,0)	ARIMA(4,1,4)	ARIMA(4,1,4)
去除四年區間	ARIMA(2,1,2)	ARIMA(1,1,1)	ARIMA(2,1,2)	ARIMA(0,1,1)
每 小 時 區 間	ARIMA(0,1,0)	ARIMA(0,1,0)	ARIMA(0,1,0)	ARIMA(0,1,0)

## (二) Weka timeseriesForecasting 套件設定

Weka 預測方面，則是用其所提供的套件 timeseriesForecasting，針對每日週期還是每小時週期，都需要根據資料集的特性設定不同的參數。其中，滯後值 (lag)<sup>4</sup>的設定也受到週期性變化的影響。具體的參數設定如下所示，詳細資訊可參考表 6。

表 6. Weka timeseriesForecasting 套件設定值

參數設定	設定值	
	每日週期	每小時週期
add day of week	True	False
add weekend indicator	True	False
remove leading instances with unknown lag values	True	True
include powers of time	True	True
include timelag products	True	True
min lag	1	1
max lag	7	12
periodicity	DAILY	HOURLY

此外在 Holt-Winters 指數平滑模型中，平滑因子包括水準 (Level)、趨勢 (Trend) 和季節性 (Seasonality)。水準平滑因子控制模型對過去數據的敏感程

<sup>4</sup> 滯後值是指在時間序列中，某個變量在過去的某個時間點的值。

度，趨勢平滑因子影響模型對趨勢變化的反應速度，而季節性平滑因子則調節模型對季節性變化的敏感度。通常因子範圍介於 0 至 1 之間，本研究首先測試比特幣全部區間，初始化三個平滑因子設定值為 0.1，並計算預測誤差(RMSE)，隨後根據預測誤差，調整平滑因子的值，直到找到最優的平滑因子組合，具體的參數設定如下表 7 所示。

表 7. Holt-Winters 平滑因子設定值

參數設定	設定值
Level Smoothing Factor( $\alpha$ )	0.8
Trend Smoothing Factor( $\beta$ )	0.3
Seasonality Smoothing Factor( $\gamma$ )	0.8

### (三) Prophet 套件設定

在 Prophet 的設定部分為與其他套件有公平比較基準，則全部區間都採用前 7 期的值當 regressor，而每小時區間則是前 12 期。隨後加入自定的週期性(add\_seasonality)至模型中，自定週期為一傅立葉函數，其次數(Fourier)及週期(Period)則使用驗證資料集獲得。表 8 為透過 sklearn 的 ParameterGrid 所得的最佳參數。

表 8. Prophet 套件設定值

資料集	比特幣		以太幣		幣安幣		泰達幣	
	Fourier	Period	Fourier	Period	Fourier	Period	Fourier	Period
全 部 區 間	35	56	5	63	45	63	15	7
去除兩年區間	20	28	30	42	25	35	5	56
去除四年區間	20	28	20	63	20	63	30	7
每 小 時 區 間	5	12	5	24	15	120	10	48

### (四) 深度學習模型套件設定(TensorFlow)

考慮到加密貨幣市場的預測需求，TensorFlow 具有強大的計算能力，適合於訓練大型模型，從而提高預測精度，而 PyTorch 提供的時間序列預測模型不如



TensorFlow 豐富。因此，本研究選擇使用 TensorFlow 建立深度學習模型。針對資料可能存在離群值的情況，本研究資料進行 z-score 的標準化轉換 (StandardScaler)。z-score 所使用的平均值和標準差都是從訓練資料中獲得的，然後再帶入測試集進行轉換，以確保評估的客觀性。深度學習模型的回溯期數 (look back)，與先前描述一樣，全部區間都是採用前 7 期作為設定值，而每小時區間則採用前 12 期。深度學習模型的層數、節點數(units)和批次大小 (batch size)都是通過從標準化轉換後的訓練集中切出 10%作為驗證集，使用 keras-tuner 套件進行參數調整獲得的，其中節點數最小值設為 100，最大值為 256，間隔(step)為 16。表 9 至表 12 顯示了 keras-tuner 探索出的最佳批次大小。

表 9. keras-tuner (LSTM)探索最佳參數

資料集	比特幣	以太幣	幣安幣	泰達幣
	batch size	batch size	batch size	batch size
全部區間	4	32	4	16
去除兩年	16	16	32	4
去除四年	4	32	16	4
每小時區間	8	16	32	16

表 10. keras-tuner (BiLSTM)探索最佳參數

資料集	比特幣	以太幣	幣安幣	泰達幣
	batch size	batch size	batch size	batch size
全部區間	16	8	8	32
去除兩年	16	16	16	32
去除四年	16	16	32	32
每小時區間	32	16	16	16

表 11. keras-tuner (CNN)探索最佳參數

資料集	比特幣	以太幣	幣安幣	泰達幣
	batch size	batch size	batch size	batch size
全部區間	32	16	16	8
去除兩年	32	16	8	16
去除四年	32	32	8	32
每小時區間	32	4	32	4

表 12. keras-tuner (CNN+LSTM)探索最佳參數

資料集	比特幣	以太幣	幣安幣	泰達幣
	batch size	batch size	batch size	batch size
全部區間	32	16	16	32
去除兩年	32	8	32	32
去除四年	8	16	16	32
每小時區間	8	4	16	4

使用比特幣全部區間初步測試後，發現 LSTM 模型僅需一個 LSTM 層可有較高準確率，而 BiLSTM 模型則使用兩個 BiLSTM 層。LSTM 模型具有較強的捕捉時間序列趨勢的能力，而 BiLSTM 模型則可以通過雙向傳遞訊息，更好地捕捉時間序列的長程依賴關係。圖 3 至圖 6 為模型架構圖。

#### 四、評估模型

為了客觀評估模型性能，公平地比較不同模型，並確保實驗結果的可靠性，本研究資料集分割成訓練集和測試集 70%/30%。與傳統切割不同，以往都以隨機切割(Random Split)方式進行，而時間序列中建立模型時不能更改時間序列的順序，需使用時間順序切割(Time-based Split)，因此本研究前期 70%資料用於訓練，後期 30%資料用於測試。

在評估模型性能的過程中，使用平均絕對誤差(MAE)和均方根誤差(RMSE)作為主要的評估指標。MAE 是衡量預測值與實際值之間的平均差值，RMSE 是衡量預測值與實際值之間的平均平方差。這兩個指標不僅可以用來衡量預測準確性，還可以幫助理解模型的預測能力和效能。

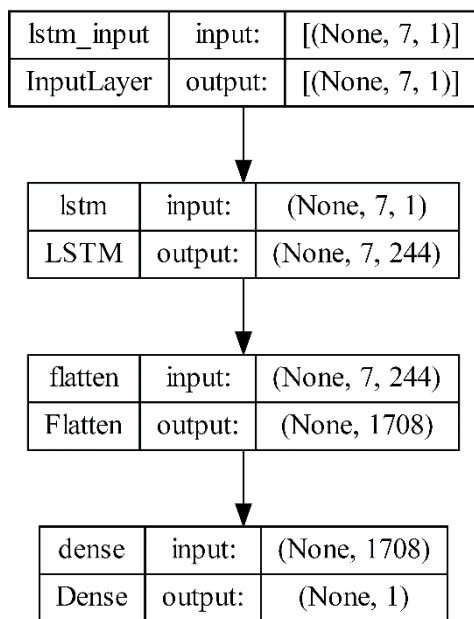


圖 3. LSTM 架構圖

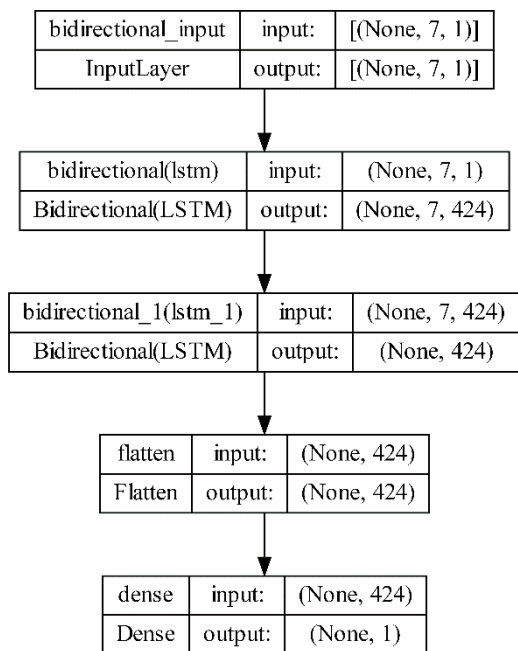


圖 4. BiLSTM 架構圖

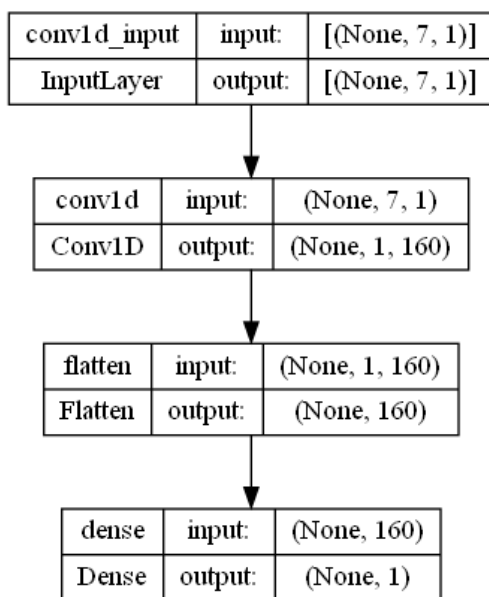


圖 5. CNN 架構圖

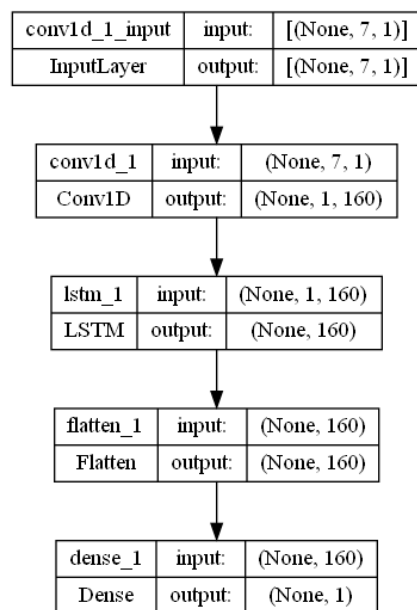


圖 6. CNN+LSTM 架構圖

## 肆、研究結果

### 一、時間序列分解

在時間序列分解中，「相加模型 (Additive Model)」和「相乘模型 (Multiplicative Model)」是兩種不同的季節性分解方法，用於將一個時間序列分解成趨勢(trend)、季節性(Seasonal)和殘差(Residual)三個部分。選擇正確的模型對於準確地捕捉時間序列的季節性模式非常重要。如果選擇錯誤的模型，可能會導致對季節性影響的錯誤估計，從而影響分析和預測的準確性。因此，在進行時間序列分解時，需要仔細考慮數據的特點和趨勢。以分解比特幣為例：




圖 7.比特幣全部區間相加模型




圖 8.比特幣全部區間相乘模型

圖由上到下分別是，原始資料、趨勢、季節性與殘差，此處比特幣以  $\text{period}=60$  為例<sup>5</sup>，並設模型為相加模型(additive)，所得的分解圖 7 如所示。可看出比特幣趨勢與原始曲線雷同，代表長期趨勢是主要變化因素，較少季節性和殘差。但

<sup>5</sup> 參數  $\text{period}$  表示每個季節性週期包含的觀察值數目。

仍需注意季節性和殘差成分，也有其重要性。顯示比特幣隨著時間的推移表現出持續增長。預測時間序列的未來值可能相對簡單，因為趨勢分量可以提供對未來值的良好估計。然而，值得注意的是，即使趨勢成分占主導地位，其殘差的後半部震幅較大，顯示仍然存在一些可能影響預測準確性的隨機變化，需要對模型進行修正。若比特幣模型改為相乘模型，其分解圖如圖 8 所示。可看出殘差的分佈有比較均勻。




圖 9. 比特幣每小時區間相加模型






圖 10.比特幣每小時區間相乘模型

每小時區間則是以  $\text{period}=12$  為例，使用相加模型進行分解。如圖 9 所示，分解後的趨勢與原始曲線相似，但殘差震幅較大，表明比特幣價格趨勢存在可能影響準確性的隨機變化。若模型改為相乘模型，如圖 10 所示，分解後的殘差分佈相較之下較為均勻。進一步的研究發現，其他三種加密貨幣也呈現出類似的結果(附錄 B)。

## 二、基線模型(ARIMA)

表 13 至表 16 為 ARIMA 實驗結果，代表傳統時間序列預測方法在加密貨幣市場中的表現。結果顯示，即使使用套件選擇最佳模型，在比特幣全部區間的測試集指標(MAE)為 144468.407，進一步的研究發現，去除四年區間可以縮小此狀況，MAE 為 9572.143，但仍然很大，存在過度擬合的問題。值得注意的是，泰達幣屬於穩定幣，因此其價格波動較小，不易出現過度擬合的問題。在每小時區間資料中，使用每小時資料集，在測試集上可以呈現較小誤差。上述結果進一步強調了傳統時間序列預測方法在加密貨幣市場中的局限性，如果未能充分考慮其他外部因素，例如外生變量(經濟指標、法規因素等)、季節性變化或長短期預測，可能無法建立準確的預測模型，說明加密貨幣並非單純線性資料。

表 13. 比特幣之 ARIMA 模型績效

資料集	最佳模型	RMSE		MAE	
		訓練	測試	訓練	測試
全部區間	ARIMA(6,2,4)	435.0950	166544.6165	175.7276	144468.407
去除兩年	ARIMA(2,1,2)	817.8256	21173.5269	394.0080	19335.744
去除四年	ARIMA(2,1,2)	1127.7645	10703.5583	622.4628	9572.143
每小時區間	ARIMA(0,1,0)	179.5368	1577.9562	1722.0549	1761.671

表 14. 以太幣之 ARIMA 模型績效

資料集	最佳模型	RMSE		MAE	
		訓練	測試	訓練	測試
全部區間	ARIMA(2,1,3)	77.2829	1270.9227	37.3667	1186.3498
去除兩年	ARIMA(1,1,0)	102.1727	276.2838	60.4694	217.4045
去除四年	ARIMA(1,1,1)	206.1082	340.1519	70.9895	311.3127
每小時區間	ARIMA(0,1,0)	11.1732	82.6203	118.0977	120.7784



表 15. 幣安幣之 ARIMA 模型績效

資料集	最佳模型	RMSE		MAE	
		訓練	測試	訓練	測試
全部區間	ARIMA(4,1,2)	12.3883	123.9009	4.7212	112.8027
去除兩年	ARIMA(4,1,4)	16.0888	45.9543	8.4877	38.6488
去除四年	ARIMA(0,1,1)	28.7834	103.2082	9.7875	96.8964
每小時區間	ARIMA(0,1,0)	1.5450	10.3521	4.6394	5.5564

表 16. 泰達幣之 ARIMA 模型績效

資料集	最佳模型	RMSE		MAE	
		訓練	測試	訓練	測試
全部區間	ARIMA(2,1,2)	0.0259	0.0008	0.0029	0.0005
去除兩年	ARIMA(0,1,3)	0.0315	0.0026	0.0020	0.0022
去除四年	ARIMA(0,1,3)	0.0439	0.0006	0.0021	0.0005
每小時區間	ARIMA(1,1,1)	0.0021	0.0451	0.0002	0.0002

### 三、時間序列預測套件(Weka、Prophet)實驗結果

表 17 至表 20 為套件(Weka、Prophet)實驗結果，比較了 Weka 套件不同時間序列模型與 Prophet 套件在加密貨幣價格預測中的表現。結果表明，Holt-Winters 模型在不同區間或不同資料週期上，多數情況下都較於傳統基於統計的 SVM 和線性迴歸表現較佳。相反地，雖然隨機森林在訓練集(全部區間、去除兩年區間、去除四年區間)上表現突出，但在測試集上的表現卻未達到預期，顯示模型有過度擬合的傾向，表示模型無法泛化到未知數據而導致準確度下降。

可以看到在去除四年間區間資料與全部區間對比後，比特幣、以太幣與幣安幣測試集誤差值均有下降，說明去除加密貨幣前半段平坦部分，可以有效降低模型的誤差。而泰達幣由於本身的特性，去除情況較為不明顯。透過適當的設定值，利用套件可以建立出比傳統時間序列更準確的模型，但在選擇模型時，需要考慮資料特性並選擇合適的設定值，以避免過度擬合的問題。

表 17. 全部區間加密貨幣在套件模型績效

資料集	比特幣				以太幣			
模型	RMSE		MAE		RMSE		MAE	
	訓練	測試	訓練	測試	訓練	測試	訓練	測試
線性迴歸	445.6805	1534.8994	174.0243	1109.5230	76.6395	125.7182	37.0464	111.3589
SVM 迴歸	458.7361	1544.6100	172.1661	1083.1003	77.1937	132.3161	36.5874	116.8381
隨機森林	226.7076	10318.6372	141.4796	9513.1313	37.3795	363.9538	26.2656	341.3313
Holt-Winters	<b>502.6638</b>	<b>1360.8980</b>	<b>178.0341</b>	<b>822.5961</b>	<b>85.5361</b>	<b>71.8278</b>	<b>41.1168</b>	<b>49.3530</b>
Prophet	435.6344	1394.1414	201.8617	1050.5384	75.4299	131.4065	38.6500	117.7411
資料集	幣安幣				泰達幣			
模型	RMSE		MAE		RMSE		MAE	
	訓練	測試	訓練	測試	訓練	測試	訓練	測試
線性迴歸	12.2899	27.6010	4.9467	23.6657	0.0043	0.0009	0.0022	0.0007
SVM 迴歸	12.4520	12.9765	4.6542	10.6570	0.0043	0.0020	0.0022	0.0017
隨機森林	5.9273	59.5947	4.1244	52.7571	0.0017	0.0006	0.0009	0.0004
Holt-Winters	<b>13.9517</b>	<b>10.0949</b>	<b>5.2646</b>	<b>6.7770</b>	<b>0.0056</b>	<b>0.0004</b>	<b>0.0029</b>	<b>0.0002</b>
Prophet	11.9331	14.9310	5.7858	12.6102	0.0042	0.0009	0.0022	0.0007

表 18. 去除兩年區間加密貨幣在套件模型績效

資料集	比特幣				以太幣			
模型	RMSE		MAE		RMSE		MAE	
	訓練	測試	訓練	測試	訓練	測試	訓練	測試
線性迴歸	816.8485	1663.1538	391.5806	1436.6842	99.8868	264.6833	59.5265	219.8927
SVM 迴歸	823.0064	1563.3468	388.0816	1332.2693	100.6584	122.6376	59.3079	102.0241
隨機森林	423.3937	7058.4878	291.6390	6498.3006	47.3984	82.8595	33.4079	63.6615
Holt-Winters	<b>882.1679</b>	<b>1070.8141</b>	<b>426.4281</b>	<b>714.5909</b>	<b>111.7263</b>	<b>50.7382</b>	<b>66.3530</b>	<b>35.2055</b>
Prophet	805.0419	1343.1562	417.7093	1110.0862	97.1942	131.6439	61.8899	113.4521
資料集	幣安幣				泰達幣			
模型	RMSE		MAE		RMSE		MAE	
	訓練	測試	訓練	測試	訓練	測試	訓練	測試
線性迴歸	15.9289	29.1247	8.6734	24.6280	0.0027	0.0010	0.0011	0.0008
SVM 迴歸	16.2332	9.0126	8.4554	6.9191	0.0028	0.0010	0.0010	0.0008
隨機森林	7.0483	20.7453	4.6435	16.7341	0.0010	0.0006	0.0005	0.0003
Holt-Winters	<b>18.1407</b>	<b>7.9098</b>	<b>9.5301</b>	<b>5.2397</b>	<b>0.0039</b>	<b>0.0005</b>	<b>0.0015</b>	<b>0.0002</b>
Prophet	15.4746	10.6597	9.3260	8.4515	0.0026	0.0026	0.0011	0.0022

表 19. 去除四年區間加密貨幣在套件模型績效

資料集	比特幣				以太幣			
模型	RMSE		MAE		RMSE		MAE	
	訓練	測試	訓練	測試	訓練	測試	訓練	測試
線性迴歸	1112.4146	964.6775	623.8671	717.9260	90.0101	93.3762	62.9800	79.4586
SVM 迴歸	1118.2478	706.0669	615.7644	499.1975	92.2182	90.2799	62.7320	77.1431
隨機森林	528.5680	6767.3135	368.8510	6214.2983	38.4107	97.0756	28.4293	89.3753
Holt-Winters	<b>1204.9975</b>	<b>709.6338</b>	<b>689.9767</b>	<b>491.9883</b>	<b>101.0523</b>	<b>44.2334</b>	<b>70.9137</b>	<b>30.3401</b>
Prophet	1082.7759	958.4279	647.7834	738.8225	86.8249	53.5516	62.7020	42.4015
資料集	幣安幣				泰達幣			
模型	RMSE		MAE		RMSE		MAE	
	訓練	測試	訓練	測試	訓練	測試	訓練	測試
線性迴歸	12.3224	6.5893	8.7095	4.8113	0.0004	0.0006	0.0002	0.0005
SVM 迴歸	12.5447	18.4021	8.5545	15.9142	0.0004	0.0003	0.0002	0.0002
隨機森林	4.8179	30.2160	3.4601	26.8088	0.0002	0.0004	0.0001	0.0003
Holt-Winters	<b>13.9371</b>	<b>5.8871</b>	<b>9.6555</b>	<b>3.9896</b>	<b>0.0005</b>	<b>0.0003</b>	<b>0.0002</b>	<b>0.0002</b>
Prophet	11.9068	9.2628	8.5771	7.6176	0.0004	0.0006	0.0002	0.0005

表 20. 每小時區間加密貨幣在套件模型績效

資料集	比特幣				以太幣			
模型	RMSE		MAE		RMSE		MAE	
	訓練	測試	訓練	測試	訓練	測試	訓練	測試
線性迴歸	108.2501	161.9557	186.8777	223.9728	7.5281	10.6433	8.6316	10.5158
SVM 迴歸	106.6780	164.3114	151.3786	185.4526	7.3261	10.8720	9.5025	11.4382
隨機森林	42.5438	63.4392	575.2893	636.5438	2.9487	4.0989	33.3973	37.1561
Holt-Winters	<b>121.4427</b>	<b>176.3889</b>	<b>98.9862</b>	<b>140.5060</b>	<b>8.2388</b>	<b>11.6403</b>	<b>6.5953</b>	<b>8.9264</b>
Prophet	150.9409	573.9939	103.8557	497.6391	10.1112	109.2577	7.2318	87.4836
資料集	幣安幣				泰達幣			
模型	RMSE		MAE		RMSE		MAE	
	訓練	測試	訓練	測試	訓練	測試	訓練	測試
線性迴歸	1.0515	1.8203	2.7563	3.0620	0.0001	0.0001	0.0002	0.0002
SVM 迴歸	1.0256	1.8682	0.8819	1.1481	0.0001	0.0001	0.0002	0.0002
隨機森林	0.4253	0.7264	4.2110	4.9469	0.0001	0.0001	0.0001	0.0001
Holt-Winters	<b>1.1965</b>	<b>2.0468</b>	<b>0.7809</b>	<b>1.1506</b>	<b>0.0001</b>	<b>0.0002</b>	<b>0.0001</b>	<b>0.0002</b>
Prophet	1.7117	165.3186	1.0825	137.6749	0.0001	0.0025	0.0001	0.0020

#### 四、深度學習模型(LSTM、BiLSTM、CNN、LSTM+CNN)實驗結果

通過時間序列分解，可以明顯看出，不論是每日週期還是每小時週期，都不是單純的相加模型，四種加密貨幣亦是如此。使用相乘模型可以使殘差的分佈更加均勻。針對資料可能是相乘模型的情況，在建立模型前，先針對資料進行對數轉換（ $\ln$ ）。本研究通過對比不同深度學習模型，總體上來說 LSTM 表現較佳，尤其在比特幣上表現最為明顯。與上節時間序列預測套件結果類似，使用高頻率的資料擷取也能夠更精確地建立預測模型。

綜合上述結果，使用有根據的預處理可以使深度學習模式準確度有所提升。然而，在實務中，要實現高頻率資料擷取仍是一大挑戰。一方面，高頻率資料的收集需要較多的成本和資源；另一方面，高頻率資料的儲存和處理也具有一定的難度。深度學習模型雖然可以建立準確的預測模型，但其訓練時間較長。而基於統計的模型訓練時間較短，但其準確度較低。因此，在選擇模型時需要權衡準確度和時間成本。

表 21. 深度學習模型在比特幣上的績效

資料集	模型	RMSE		MAE	
		訓練	測試	訓練	測試
全部區間	LSTM	464.5991	1294.1110	181.4643	802.2682
	BiLSTM	461.1700	1312.0138	176.9370	811.7655
	CNN	<b>467.7072</b>	<b>1290.4827</b>	<b>171.2382</b>	<b>796.3051</b>
	LSTM+CNN	621.3378	2279.3907	306.0596	1556.1854
去除兩年區間	LSTM	<b>828.7567</b>	<b>1005.0984</b>	<b>390.1384</b>	<b>630.8911</b>
	BiLSTM	920.3227	1166.0943	442.2400	748.2552
	CNN	927.4559	1186.8362	442.6164	826.2467
	LSTM+CNN	876.9087	1222.8991	409.6179	886.4437
去除四年區間	LSTM	<b>1157.0639</b>	<b>691.3576</b>	<b>645.9617</b>	<b>442.5901</b>
	BiLSTM	1335.1487	695.6725	742.6850	453.8327
	CNN	1145.7811	1205.2545	720.7684	676.0730
	LSTM+CNN	1172.3018	802.7809	661.6095	588.5365
每小時區間區	LSTM	<b>164.4821</b>	<b>134.4446</b>	<b>106.1263</b>	<b>93.3940</b>
	BiLSTM	175.9570	137.6790	116.6126	97.1418
	CNN	161.8095	161.8095	138.5228	104.2609
	LSTM+CNN	162.2246	216.3676	105.6397	179.6863

表 22. 深度學習模型在以太幣上的績效

資料集	模型	RMSE		MAE	
		訓練	測試	訓練	測試
全部區間	LSTM	<b>77.3488</b>	<b>67.1492</b>	<b>36.7008</b>	<b>45.7634</b>
	BiLSTM	99.7231	75.0257	47.2820	51.6483
	CNN	78.7574	70.0520	37.3861	48.7421
	LSTM+CNN	92.9944	117.1386	44.7551	95.6490
去除兩年區間	LSTM	<b>101.5694</b>	<b>46.8637</b>	<b>59.7434</b>	<b>31.5250</b>
	BiLSTM	103.9571	47.8904	61.5010	33.2819
	CNN	104.5208	50.7869	61.8353	36.6826
	LSTM+CNN	101.6130	51.6720	59.7004	38.3275
去除四年區間	LSTM	<b>96.7070</b>	<b>41.0682</b>	<b>64.2055</b>	<b>26.3775</b>
	BiLSTM	103.3870	41.8485	70.3649	27.4271
	CNN	92.8735	45.7843	63.9476	32.7329
	LSTM+CNN	94.3656	40.5251	63.9153	26.6440
每小時區間區	LSTM	<b>10.8836</b>	<b>8.2617</b>	<b>7.4398</b>	<b>5.9440</b>
	BiLSTM	11.0562	8.1872	7.6108	5.9536
	CNN	10.9196	8.5039	7.6913	6.3779
	LSTM+CNN	11.6327	9.5006	8.0683	7.1672

表 23. 深度學習模型在幣安幣上的績效

資料集	模型	RMSE		MAE	
		訓練	測試	訓練	測試
全部區間	LSTM	12.6351	9.8566	4.7689	6.8798
	BiLSTM	<b>12.6337</b>	<b>9.5261</b>	<b>4.7668</b>	<b>6.6669</b>
	CNN	15.3344	17.4575	6.1593	14.9159
	LSTM+CNN	15.4868	24.8111	6.2918	22.8740
去除兩年區間	LSTM	<b>16.7134</b>	<b>7.3921</b>	<b>8.9113</b>	<b>4.6491</b>
	BiLSTM	17.1614	7.3481	9.1664	4.6789
	CNN	16.6174	7.9511	8.6758	5.5555
	LSTM+CNN	16.4902	8.3211	8.6360	6.0315
去除四年區間	LSTM	12.6208	5.5036	8.6839	3.6106
	BiLSTM	<b>12.8913</b>	<b>5.4134</b>	<b>8.8502</b>	<b>3.5762</b>
	CNN	12.6773	6.3255	8.7296	4.7527
	LSTM+CNN	12.6320	5.8773	8.5943	4.1201
每小時區間區	LSTM	<b>1.9438</b>	<b>0.9076</b>	<b>1.0821</b>	<b>0.6713</b>
	BiLSTM	1.8911	1.0717	1.0446	0.8496
	CNN	1.9639	1.0464	1.0329	0.7745
	LSTM+CNN	1.9477	1.1061	1.0880	0.7881

表 24. 深度學習模型在泰達幣上的績效

資料集	模型	RMSE		MAE	
		訓練	測試	訓練	測試
全部區間	LSTM	0.0041	0.0004	0.0021	0.0002
	BiLSTM	0.0042	0.0004	0.0022	0.0002
	CNN	0.0040	0.0005	0.0020	0.0002
	LSTM+CNN	<b>0.0036</b>	<b>0.0005</b>	<b>0.0018</b>	<b>0.0002</b>
去除兩年區間	LSTM	0.0024	0.0005	0.0009	0.0002
	BiLSTM	0.0025	0.0005	0.0009	0.0002
	CNN	0.0024	0.0006	0.0008	0.0002
	LSTM+CNN	<b>0.0022</b>	<b>0.0005</b>	<b>0.0007</b>	<b>0.0002</b>
去除四年區間	LSTM	0.0005	0.0003	0.0002	0.0002
	BiLSTM	0.0005	0.0003	0.0002	0.0002
	CNN	0.0005	0.0003	0.0002	0.0002
	LSTM+CNN	<b>0.0005</b>	<b>0.0003</b>	<b>0.0002</b>	<b>0.0002</b>
每小時區間區	LSTM	0.0001	0.0001	0.0001	0.0001
	BiLSTM	0.0001	0.0001	0.0001	0.0001
	CNN	0.0001	0.0001	0.0001	0.0001
	LSTM+CNN	<b>0.0001</b>	<b>0.0001</b>	<b>0.0001</b>	<b>0.0001</b>

## 五、實驗結果小結

本研究以當前主流加密貨幣為研究對象，包括比特幣、幣安幣、以太幣和泰達幣。此外，考慮到穩定幣的特性，加入了穩定幣(泰達幣)進行觀察。實驗結果如表 24 所示，在比特幣全部區間內，使用 Weka 套件並基礎學習器設定為 Holt-Winters 的 MAE 為 822.59。而去除四年區間後，MAE 進一步降低至 491.98。說明初期資料可能無法或甚至會誤導模型的訓練。模型方面，在去除四年區間的比特幣測試集中，CNN 模型的平均絕對誤差(MAE)為 588.53，LSTM 模型的 MAE 為 442.59，相較於傳統時間預測方法 ARIMA 的 MAE 為 9572.14，大幅降低了。而在訓練集中表現最好的隨機森林，在測試集中出現過度擬合的現象，MAE 為

6214.29。ARIMA 誤差值過大，可能是因為模型未考慮到其他因素，如經濟指標、法規因素等，本研究只採取較為單純的收盤價作為目標。而在所有模型中大多數 LSTM 表現都是表現最佳的，在以太幣中尤為明顯，而其次為 Weka 套件中的 Holt-Winters，在去除四年區間尤為明顯。先前研究中表示 BiLSTM 可以建立準確的預測模型，但本研究採用不同資料特徵值，並未納入經濟指標作為輔助預測因子，因此結果先前研究有所不同。此外，泰達幣誤差值始終很低，代表研究所建立的模型可以有效預測貨幣，如果連穩定性高的泰達幣所建立的模型誤差都很大，則代表模型可能在建立時就是錯誤的，而誤差值很低，也代表其投資價值不高，這也是過往研究不納入泰達幣比較的原因之一。

表 25. 比特幣全部區間與去除四年區間模型績效比較摘要表

全部區間			去除四年區間		
模型	MAE		模型	MAE	
	訓練	測試		訓練	測試
ARIMA(6,2,4)	175.7276	144468.407	ARIMA(2,1,2)	622.4628	9572.143
Holt-Winters	178.0341	822.5961	Holt-Winters	689.9767	491.9883
LSTM	181.4643	802.2682	LSTM	<b>645.9617</b>	<b>442.5901</b>
CNN	<b>171.2382</b>	<b>796.3051</b>	CNN	676.0730	488.0410

表 26. 以太幣全部區間與去除四年區間模型績效比較摘要表

全部區間			去除四年區間		
模型	MAE		模型	MAE	
	訓練	測試		訓練	測試
ARIMA(2,1,3)	37.3667	1186.3498	ARIMA(1,1,1)	70.9895	311.3127
Holt-Winters	41.1168	49.3530	Holt-Winters	70.9137	30.3401
LSTM	<b>36.7008</b>	<b>45.7634</b>	LSTM	<b>64.2055</b>	<b>26.3775</b>
CNN	37.3861	48.7421	CNN	63.9476	32.7329

表 27. 幣安幣全部區間與去除四年區間模型績效比較摘要表

全部區間			去除四年區間		
模型	MAE		模型	MAE	
	訓練	測試		訓練	測試
ARIMA(4,1,2)	4.7212	112.8027	ARIMA(2,1,2)	9.7875	96.8964
Holt-Winters	5.2646	6.7770	Holt-Winters	9.6555	3.9896
LSTM	4.7689	6.8798	LSTM	8.6839	3.6106
BiLSTM	<b>4.7668</b>	<b>6.6669</b>	BiLSTM	<b>8.8502</b>	<b>3.5762</b>

表 28. 泰達幣全部區間與去除四年區間模型績效比較摘要表

全部區間			去除四年區間		
模型	MAE		模型	MAE	
	訓練	測試		訓練	測試
ARIMA(2,1,2)	0.0029	0.0005	ARIMA(0,1,3)	0.0021	0.0005
Holt-Winters	0.0029	0.0002	Holt-Winters	0.0002	0.0002
LSTM	0.0021	0.0002	LSTM	0.0002	0.0002
LSTM+CNN	<b>0.0018</b>	<b>0.0002</b>	LSTM+CNN	<b>0.0002</b>	<b>0.0002</b>



## 伍、結論

加密貨幣市場近年來迅速發展，成為全球投資者關注的焦點。然而，加密貨幣價格波動劇烈，預測其走勢是一項具有挑戰性的任務。本研究旨在比較套件及基於前處理之深度學習模型在預測加密貨幣表現的效果，選擇市場上較為知名的貨幣包括比特幣、以太幣、幣安幣以及泰達幣。

本研究顯示，傳統時間序列模型如果不考慮外生變數，模型表現可說是差強人意，即使透過正確的模型篩選也是如此，說明加密貨幣並非單純線性模型。不同的是，Weka 的時間序列預測套件可以獲得不錯的結果，在本研究的所有測試資料集中，當根據資料性質不同，調整適當的參數值，並且基礎學習器是 Holt-Winters 時表現最好。

Prophet 在未做參數調整與未加入前幾期收盤價當 regressor 時測試集的誤差會相當大。但這並非表示 Prophet 的表現不好。相反地，Prophet 在長期預測上表現算是相當良好。但由於要進行客觀的比較，因此本研究加入前 7 期當 regressor，並加入自訂週期來進行模型訓練與評估。結果顯示其表現可與 Weka 表現相當。

在深度學習方面，本研究依據資料的特性進行對數轉換(假設時間序列資料為相乘模型)，並以訓練集進行標準化處理，接著再進行模型訓練，結果正確率有明顯提升，改善初學者無法獲得好的預測模型的問題。

在加密貨幣市場中，使用深度學習模型可以捕捉其趨勢和季節性等特徵。而使用套件進行預測，並使用適當的參數，也可以取得不錯的結果甚至超過深度學習模型。此外，不同幣種在模型上也有同樣結果。穩定幣由於其性質格波動較小，模型之間誤差較小，實務上難以取得高額收益。實務應用上，高頻率資料的取得和處理成本較高，且模型的建立和更新時間較長，可能會影響交易時效性。因此，是否能將高頻率資料應用於實務上仍是一大挑戰。

## 參考文獻

- [1] Alonso-Monsalve, Saúl, Andrés L. Suárez-Cetrulo, Alejandro Cervantes, and David Quintana (2020), "Convolution on neural networks for high-frequency trend prediction of cryptocurrency exchange rates using technical indicators", Expert Systems with Applications, Volume 149, doi: [10.1016/j.eswa.2020.113250](https://doi.org/10.1016/j.eswa.2020.113250).
- [2] Amaris, Marcos, Raphael Camargo, Daniel Cordeiro, Alfredo Goldman, and Denis Trystram (2023), "Evaluating execution time predictions on GPU kernels using an analytical model and machine learning techniques," Journal of Parallel and Distributed Computing, Volume 171, Pages 66-78, doi: [10.1016/j.jpdc.2022.09.002](https://doi.org/10.1016/j.jpdc.2022.09.002).
- [3] Bryant, A., and Follett L. , "Hunger relief: A natural experiment from additional SNAP benefits during the COVID-19 pandemic." Lancet Reg Health Am. 2022 Jun;10:100224. doi: [10.1016/j.lana.2022.100224](https://doi.org/10.1016/j.lana.2022.100224).
- [4] Dae, Abdulhafidhl F., U. Yavuz and A. A. Almohammed, "Performance Evaluation of Time Series Forecasting Methods in The Stock Market: A Comparative Study", 2022 International Conference on Decision Aid Sciences and Applications (DASA), Chiangrai, Thailand, 2022, pp. 1510-1514, doi: [10.1109/DASA54658.2022.9765177](https://doi.org/10.1109/DASA54658.2022.9765177).
- [5] Devi, A. U., R. Vishal Kumar, P. S. Priya, M. S. Amzad Basha, M. M. Sucharitha and P. M. Oveis, "A Data Mining approach on the Performance of Machine Learning Methods for Share Price Forecasting using the Weka Environment", 2023 Fifth International Conference on Electrical, Computer and Communication Technologies (ICECCT), Erode, India, 2023, pp. 01-06, doi: [10.1109/ICECCT56650.2023.10179772](https://doi.org/10.1109/ICECCT56650.2023.10179772).
- [6] Durairaj, M. and B.H. Krishna Mohan (2019). "A Review of Two Decades of Deep Learning Hybrids for Financial Time Series Prediction", International Journal on Emerging Technologies 10(3): 324-331, doi:[10.3390/engproc2023039079](https://doi.org/10.3390/engproc2023039079).
- [7] Fan, J. and Z. Wang, "Comparing different deep learning models for cryptocurrency forecasting", 2023 2nd International Conference on Data Analytics, Computing and Artificial Intelligence (ICDACAI), Zakopane, Poland, 2023, pp. 801-806, doi: [10.1109/ICDACAI59742.2023.00157](https://doi.org/10.1109/ICDACAI59742.2023.00157).
- [8] Goutte, S., Le, hoang Viet , Liu , fei, & Mettenheim, H. J. von. (2023). Deep Learning and Technical Analysis in Cryptocurrency Market. Finance Research Letters, 54(103809). doi:[10.1016/j.frl.2023.103809](https://doi.org/10.1016/j.frl.2023.103809).
- [9] Iha, T., Kawamitsu, I., Ohshiro, A., and Nakamura, M. (2019). An LSTM-based multivariate time series predicting method for number of restaurant customers in tourism resorts, International Technical Conference on Circuits/Systems,

- Computers and Communications. doi: [10.1109/ITC-CSCC52171.2021.9501432](https://doi.org/10.1109/ITC-CSCC52171.2021.9501432).
- [10] Iyengar, N. Ch. S. N., and Reddy, P. N. (2017). Comparative study of time series predictive models. *International Journal of Grid and Distributed Computing*, 10(8), pp. 45-54. doi:[10.14257/ijgdc.2017.10.8.05](https://doi.org/10.14257/ijgdc.2017.10.8.05).
- [11] Khayyat, B., F. Harrou and Y. Sun, "Predicting COVID-19 Spread using Simple Time-Series Statistical Models", 2021 International Conference on ICT for Smart Society (ICISS), Bandung, Indonesia, 2021, pp. 1-5, doi: [10.1109/ICISS53185.2021.9533192](https://doi.org/10.1109/ICISS53185.2021.9533192).
- [12] Lakshmanarao, A., M. R. Babu, C. Gupta and A. S. G. Lakshmi, "Stock Price Prediction using Deep Learning and FLASK", 2022 International Conference on Innovative Computing, Intelligent Communication and Smart Electrical Systems (ICSES), Chennai, India, 2022, pp. 1-5, doi: [10.1109/ICSES55317.2022.9914347](https://doi.org/10.1109/ICSES55317.2022.9914347).
- [13] Lara-Benítez, Pedro ,Manuel Carranza-García and Jose C. Riquelme (2021). "An Experimental Review on Deep Learning Architectures for Time Series Forecasting", *International Journal of Neural Systems*, doi:[10.1142/S0129065721300011](https://doi.org/10.1142/S0129065721300011).
- [14] Law, S. M. (2019). STUMPY: A Powerful and Scalable Python Library for Time Series Data Mining. *Journal of Open Source Software*, 4(39), 1504, doi:[10.21105/joss.01504](https://doi.org/10.21105/joss.01504).
- [15] Li, T. (2020). Application analysis of financial time series in stock market. *Proceedings of the 2nd International Conference on Business and Policy Studies*. doi:[10.54254/2754-1169/13/20230744](https://doi.org/10.54254/2754-1169/13/20230744).
- [16] Liu, Z., Z. Zhu, J. Gao and C. Xu, "Forecast Methods for Time Series Data: A Survey", in *IEEE Access*, vol. 9, pp. 91896-91912, 2021, doi: [10.1109/ACCESS.2021.3091162](https://doi.org/10.1109/ACCESS.2021.3091162).
- [17] Liu, Z., Lai, K. K., and Chen, Y. (2019). Forecast methods for time series data: A survey. *Information Fusion*, 52, pp. 1-23. doi: 10.1016/j.inffus.2019.01.004.
- [18] Maeda, K., Kurebayashi, I., Komuro, N., and Hirai, K. (2021). A study on time series analysis of environmental data for predicting emotional conditions, 2021 IEEE 3rd Global Conference on Life Sciences and Technologies, doi: [10.1109/LIFETECH52111.2021.9391865](https://doi.org/10.1109/LIFETECH52111.2021.9391865).
- [19] Merlini, D., and Rossini, M. (2021). "Text categorization with WEKA: A survey.", *Machine Learning with Applications*, 4, doi: [10.1016/j.mlwa.2021.100033](https://doi.org/10.1016/j.mlwa.2021.100033).
- [20] Nagula, P.K. and C. Alexakis. "A hybrid machine learning model for predicting bitcoin prices.", *Journal of Behavioral and Experimental Finance* 36 (2022): 100741, doi: [10.1016/j.jbef.2022.100741](https://doi.org/10.1016/j.jbef.2022.100741).
- [21] P, N., R. J. Tom, P. Gupta, A. Shanthini, V. M. John and V. Sharma, "Prediction of

- Bitcoin Price Using Bi-LSTM Network", 2021 International Conference on Computer Communication and Informatics (ICCCI), Coimbatore, India, 2021, pp. 1-5, doi: [10.1109/ICCCI50826.2021.9402427](https://doi.org/10.1109/ICCCI50826.2021.9402427).
- [22] Peixeiro, M. (2022). Time Series Forecasting in Python. Manning Publications. <https://www.manning.com/books/time-series-forecasting-in-python-book>.
- [23] Priya, L. K., S. Kolanupaka, U. M. Ganta, B. Prakash Karing and S. Yallanuru, "Predicting the Prices of Cryptocurrencies using Deep Learning", 2022 6th International Conference on Computing Methodologies and Communication (ICCMC), Erode, India, 2022, pp. 76-80, doi: [10.1109/ICCMC53470.2022.9753709](https://doi.org/10.1109/ICCMC53470.2022.9753709).
- [24] Qi, H., Xiao, S., Shi, R., Ward, M. P., Chen, Y., Tu, W., Su, Q., Wang, W., Wang, X., and Zhang, Z. (2020). COVID-19 transmission in Mainland China is associated with temperature and humidity: A time-series analysis. Science of the Total Environment, 728, 138778. doi: [10.1016/j.scitotenv.2020.138778](https://doi.org/10.1016/j.scitotenv.2020.138778).
- [25] Ratakonda, S. S. and S. Sasi, "Seasonal Trend Analysis on Multi-Variate Time Series Data", 2018 International Conference on Data Science and Engineering (ICDSE), Kochi, India, 2018, pp. 1-6, doi: [10.1109/ICDSE.2018.8527804](https://doi.org/10.1109/ICDSE.2018.8527804).
- [26] Seabold, S., and Perktold, J. (2010). Statsmodels: Econometric and Statistical Modeling with Python. In Proceedings of the 9th Python in Science Conference (pp. 92-96). doi: [10.25080/Majora-92bf1922-011](https://doi.org/10.25080/Majora-92bf1922-011).
- [27] Shabani, M. and A. Iosifidis, "Low-Rank Temporal Attention-Augmented Bilinear Network for financial time-series forecasting", 2020 IEEE Symposium Series on Computational Intelligence (SSCI), Canberra, ACT, Australia, 2020, pp. 2156-2161, doi: [10.1109/SSCI47803.2020.9308440](https://doi.org/10.1109/SSCI47803.2020.9308440).
- [28] Siebert, J., Groß, J., and Schroth, C. (2021). A Systematic Review of Python Packages for Time Series Analysis. Engineering Proceedings, 5(1). doi: [10.48550/arXiv.2104.07406](https://doi.org/10.48550/arXiv.2104.07406).
- [29] Takyi, P. O., and Bentum-Ennin, I. (2021). The impact of COVID-19 on stock market performance in Africa: A Bayesian structural time series approach. Journal of Economics and Business, 115, 105968. doi: [10.1016/j.jeconbus.2020.105968](https://doi.org/10.1016/j.jeconbus.2020.105968).
- [30] Taylor, Sean J. and Benjamin Letham (2018). "Forecasting at scale" ,The American Statistician 72(1): 37-45. doi: [10.7287/peerj.preprints.3190v2](https://doi.org/10.7287/peerj.preprints.3190v2).
- [31] Yang, W., Wang, B., and Wang, R. (2020). Detection of anomaly stock price based on time series deep learning models. In 2020 Management Science Informatization and Economic Innovation Development Conference (MSIEID) ,pp. 110-114. IEEE. doi: [10.1109/MSIEID52046.2020.00029](https://doi.org/10.1109/MSIEID52046.2020.00029).
- [32] Yu, L., "Economic and Financial Data Analysis System Based on Deep Learning and Neural Network Algorithm", 2022 International Conference on Knowledge

- Engineering and Communication Systems (ICKES), Chickballapur, India, 2022, pp. 1-5, doi: [10.1109/ICKECS56523.2022.10060240](https://doi.org/10.1109/ICKECS56523.2022.10060240).
- [33] Zaychenko, Y. and O. Kuzmenko, "Investigation of hybrid deep learning networks and LSTM in the short term forecasting in financial sphere", 2022 IEEE 17th International Conference on Computer Sciences and Information Technologies (CSIT), Lviv, Ukraine, 2022, pp. 65-68, doi: [10.1109/CSIT56902.2022.10000555](https://doi.org/10.1109/CSIT56902.2022.10000555).
- [34] Zhang, C., and Sjarif, N. N. A. (2022). Deep learning models for price forecasting of financial time series: A review of recent advancements. Expert Systems with Applications, 186, 115064. doi: [10.1016/j.eswa.2022.115064](https://doi.org/10.1016/j.eswa.2022.115064).

## 附錄 A

### 委員提問與建議

王志雄老師：

- 已經知道以天為週期的加密貨幣資料所建立的預測模型不準確，還有研究的必要性嗎？

經詢問蕭老師後學生瞭解到論文初稿的說法並不正確，否則就如蕭老師說的每個人都去跑小時的模型來賺錢。但事實跑小時的模型不見得就一定獲利，而模型的 RMSE 或 MAE 較小是由於每小時改變的幅度本來就不像每日的幅度(例如原本一天可能跌幅達 10%，但每一小時去看跌幅只有 1%或 2%)，此每小時計算的 RMSE 或 MAE 自然比以日為單位的模型小，但不代表它比較好。

- 加密貨幣已經知道為非線性資料，那是否還有需要以線性模型去建立模型？

經詢問蕭老師後學生瞭解到雖然資料為非線性，但由於有加入滯後項(lag terms)所以即使用線性迴歸模型亦可處理非線性時間序列資料的預測。而隨機森林雖為非線性模型其表現亦不如線性迴歸模型。可見得線性模型在處理這類問題時仍具有相當的優勢。主要是因為線性模型在預測能力與模型複雜度之間取得了良好的平衡。雖然隨機森林等非線性模型在理論上可以處理更複雜的關係，但在實際應用中，過於複雜的模型可能會導致過度擬合，反而降低了預測的準確性。因此，即使面對非線性的數據，我們仍不應該忽視線性模型的潛力。

- ARIMA(p,d,q)是否有一個流程來決定參數設定？

因應王老師的回應，ARIMA 模型的參數設定是至關重要的，因此 ARIMA 本身有一套篩選最佳模型的程序，以確保模型的準確性。已於第參章第三節的第一小節補充說明。

- 原始資料中含有異常值是否在建立模型時，需要拿掉或處理？

經詢問蕭老師後學生瞭解到：對於時間序列資料中的異常值，是否需要在建立模型時進行處理，取決於異常值的性質和我們的預測目標。如果這些異常值是由於某種系統性的變化(例如政策改變、市場崩潰等)引起的，那麼它們可能包含了對未來趨勢預測非常重要的訊息，因此可能需要保留。然而，如果這些異常值是由於測量錯誤或其他非系統性的因素引起的，那麼它們可能會對模型造成干擾。在這種情況下，便可能需要考慮這些異常值去除，或者使用一些方法(例如平滑技術)來減少它們的影響。但由於我們並無法知道所蒐集的資料中哪些離群值是屬於哪一類的異常值，因此我們論文的做法就是採用指數轉換及標準化轉換技術來降低異常值的影響。此部份的說明請參考論文第參章第參節的第四小節說明。

- **原始資料中趨勢顯現出前半段較為平滑，與後半段相比差異較大，那是否就使用後半段建立預測模型即可？**

因應王老師的回應，針對前半平滑部分，真對前半段起伏較低的資料，本研究設計不同區間資料：全部區間、減去兩年區間、減去四年區間，以減少對於預測模型無用資料。已於第參章第三節第一節的第三小節補充說明。

- **研究到最後目的是什麼？**

因應王老師的回應，本研究針對不同特性的加密貨幣，比較使用套件或深度學習模型的優缺點，並探討資料區間與資料採集頻率對模型準確性的影響。

- **是否有比較明顯的數據資訊可證明研究結果有所提升?例如提升 20%**

因應王老師的回應，比特幣方面全部區間的 MSE 是 887.66，經過去除四年區間後變為 452.71。MSE 降低了 48.3%，證實可以提升模型準確度。已於摘要與結論中補充說明。

- **資料品質會影響模型建立，何謂「資料品質」？**

因應王老師的回應，描述過於籠統，改為「資料代表性」，假設今天要預測下一個小時溫度資料而資料集是使用每日資料或是使用上季資料，所訓練出

來得到的模型就不是所需要的。已於第壹章的第一節修改。

- **研究動機的敘述說明套件和資料集須搭配合宜才能發揮套件的預測能力；但是沒有在加密貨幣的著墨，例如，氣溫預測的例子可否改為加密貨幣的情況？**

因應王老師的回應，例如研究加密貨幣市場走向，而如今是單純使用市場價值或是天氣資料作為預測因子，顯然不是適當做法。已於第壹章的第一節修改。

- **移動平均法不適合用於有趨勢情況下的資料預測。**

因應王老師的回應，移動平均法可以用來突顯長期趨勢，但不能用來預測長期趨勢。移動平均法是一種平滑方法，可以通過計算過去一段時間的平均值來消除短期波動，從而突顯長期趨勢。移動平均法無法預測長期趨勢的變化。例如，如果資料呈現上升趨勢，移動平均值也可能繼續上升，但上升的速度可能會比實際的趨勢慢。已於第貳章的第一節修改。

- **「過度擬合」的意思？**

因應王老師的回應，補上原文(overfitting)，簡單來說就是對訓練集有很好的效果，而測試集確恰恰相反。已於第貳章的第一節補充。

- **圖形化介面「彈性不足」指得是什麼？是因為無法進行外加寫程式或其他原因？**

因應王老師的回應，圖形介面往往是方便使用者操作，而當使用者需要更精確的調整參數或客製化模型，就需要透過程式套件達成。

- **可以提出一些深度學習例子說明所需的訓練時間。**

因應王老師的回應，深度學習訓練時間依據訓練資料大小、模型層數、設定值調整或裝置限制等導致訓練時間需要幾小時到幾週都有可能，而 GPU 的並行計算能力，可以同時處理多個數據使其縮短訓練時間。

- **梯度消失、爆炸，術語可否解釋。**

因應王老師的回應，梯度消失是指梯度在反向傳播過程中逐漸趨近於 0。這



會導致神經網路的權重更新幅度非常小，從而無法有效學習。反之為梯度爆炸會導致神經網路的權重更新幅度非常大，從而導致神經網路震盪或不穩定。已於第貳章的第三節補充。

- **ARIMA 建立模型中，談到需要先將資料具平穩性，需要如何做轉換？**

因應王老師的回應，如原始資料本身不具平穩性，可以透過微分使資料平穩，本研究也是透過此方式達成目的，如再不具平穩性，可二次微分。已於第參章第三節第一小節補充說明。

- **ARIMA(p,I,q)建立模型中，p 和 q 選擇的準則？**

因應王老師的回應，p 和 q 是一種排列組合，例如 p 和 q 最高設為 5，所以會有 36 種組合(6\*6)。已於第參章第三節第一小節補充說明。

- **ARIMA(p,I,q)建立模型中，假設當前 p 和 q 組合沒有通過殘差分析，之後如何擬定新的 p 和 q？**

因應王老師的回應，如果殘差檢測沒有通過，則選用其次最低 AIC 的 p 和 q 組合。已於第參章第三節第一小節補充說明。

- **Prophet 套件設定中，其中自訂的週期性指得是什麼？**

因應王老師的回應，為前 3 期的值當回歸量。已於第參章第三節第三小節補充說明。

- **時間序列分解中，殘差都為正數表示此預測方法有偏差，可能代表此預測方法不適合這資料集。**

因應王老師的回應，已知模型存在誤差，所以在進行預測前針對資料進行對數轉換及標準化處理，並且使用機器學習法與 ARIMA 進行比較，從結果可以得知使用深度學習模型還是可以建立準確的預測模型。

- **可佐以深度學習模型所需的預測時間來說明。**

因應王老師的回應，本次研究使用收盤價進行預測，而基本的 LSTM 則需要約 30 分鐘進行訓練，若需要更準確的預測模型就需要使用到不同的特徵值，

如此一來訓練時間也不能保證可以在小時內達成。

- **文中描述過的片段，就不用再多做說明，描寫重點即可。**

因應王老師的回應，感謝教授建議，會重新閱讀並修改。

- **時間序列分解中，加法模型原圖與趨勢分解圖相似，可否用計算方式將加法量計算出來？**

因應王老師的回應，理論上是可行的，但本研究的目的是在於比較不同模型的預測效果，因此沒有深入探討加法模型與相乘模型的趨勢、季節性和殘差部分。

- **隨著後面加法模模型波動更大，可否根據時間透過深度學習調整參數，降低誤差。**

因應王老師的回應，深度學習可以通過學習時間序列的歷史數據來預測未來的趨勢、季節性和殘差。因此，可以使用深度學習來根據時間調整加法模型的參數，而本研究也透過套件去選擇最佳參數，同時也比較不同深度學習模型，期望可以得到最佳結果。

張德民老師：

- **傳統時間序列(ARIMA)是如何切割訓練集與測試集，傳統概念是以真實數據進行預測，而不是接續以預測結果再進行預測？**

因應張老師的回應，在現實情況中，由於無法獲取未來資料，因此本研究以目前的預測結果來預測下一個時間點。做法是為了與深度學習和套件保持一致，因為 ARIMA 也使用這種方式。

- **ARIMA 是否以全部資料集進行參數設定？**

因應張老師的回應，以 ARIMA 概年來說確實需要以全部資料進行參數設定，而這樣就無法評估用於預測模型，為了與現實情況相比，本研究以訓練集進行參數設定。已於第參章第四節補充說明。

- **每天週期資料集與每小時週期資料集大小是否足夠訓練模型？**

因應張老師的回應，研究結果顯示，每天週期資料集在去除四年區間後的表現比全部區間更好。這表明，過多的資料可能會影響模型的訓練。此外，每小時週期資料集使用一個月的資料即可表現良好，因此不需要額外增加資料量。已於第參章第一節第二小節補充說明。

- **移動平均有切割訓練集與測試集的概念？**

因應張老師的回應，在時間序列預測中，移動平均模型也需要切割訓練集與測試集。在切割時，需要遵守時間序列定義，即資料不可隨意更改時間順序。

- **ARIMA 流程圖是否有繪製錯誤，與報告時描述的不太一致？**

因應張老師的回應，根據建立模型過程，模型圖再以修改。已於圖 2 修改。

- **以 70% 訓練集與 30% 測試集為例，切割資料集應該沒有前後概念，應以隨機切割方式？深度學習應該也是如此？**

因應張老師的回應，傳統的深度學習模型通常採用隨機切割資料集的方式進行訓練，但這種方式在時間序列資料中存在一些缺陷。時間序列資料具有時間相關性，即前一個資料點的值會影響後一個資料點的值。因此，隨機切割會導致訓練集和測試集之間存在前後關係，從而影響模型的預測性能。因此，在本研究中，按照時間順序對資料集進行切割，即前期 70% 資料用於訓練，後期 30% 資料用於測試。已於第參章第四節補充說明。

- **ARIMA 與深度學習相比，誤差值相差甚大，是為什麼？**

因應張老師的回應，加密貨幣價格時間序列具有複雜的非線性特性，因此深度學習模型可以表現得更好。此外，加密貨幣價格還受到外生變數的影響，例如經濟因素、政策因素等。而本研究僅使用加密貨幣價格本身作為預測特徵，因此 ARIMA 模型的表現會相較於深度學習模型遜色。已於結論補充說明。

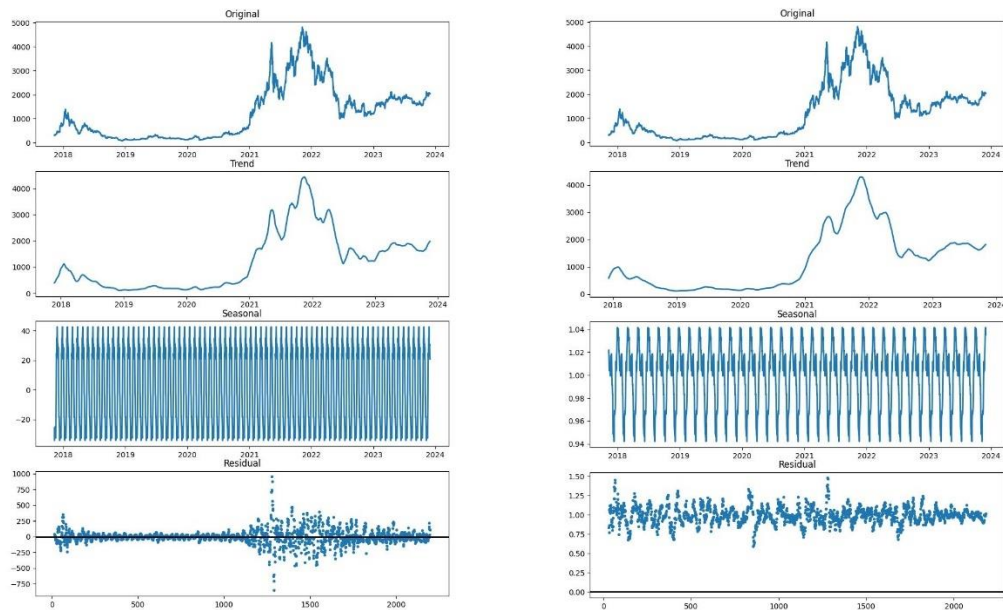
- **先前研究以證實深度學習模型已經是強大的預測工具，而研究結果再一次說**

**明此解果，主要貢獻為何？**

因應張老師的回應，相較於過往研究，研究往往都加入不同數量的指標作為特徵值，以期獲得更好的預測效果。然而，由於加密貨幣價格時間序列具有複雜的非線性特性，因此加入過多的指標反而會導致模型過度擬合，影響預測效果。因此，本研究期望透過更為簡單的特徵值，例如加密貨幣價格本身，來建立模型。透過這種方式，可以避免上述情況，並獲得更為純粹的結果。結果可以作為後續研究比較的依據，以進一步探討加密貨幣價格預測的最佳模型。已於結論補充說明。

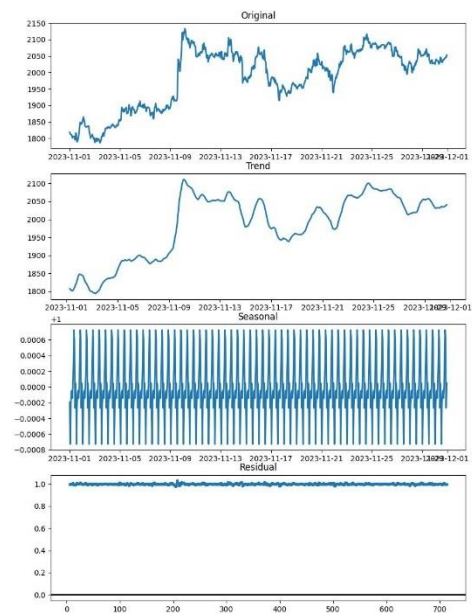

## 附錄 B

下列圖為時間序列分解圖(以太幣、幣安幣、泰達幣)，可以發現在泰達幣與幣安幣全部區間的分解圖中殘差分佈較不集中，針對此部分在建立模型前所有資料都進行對數轉換與標準化處理，並且比較不同機器學習法與深度學習模型。




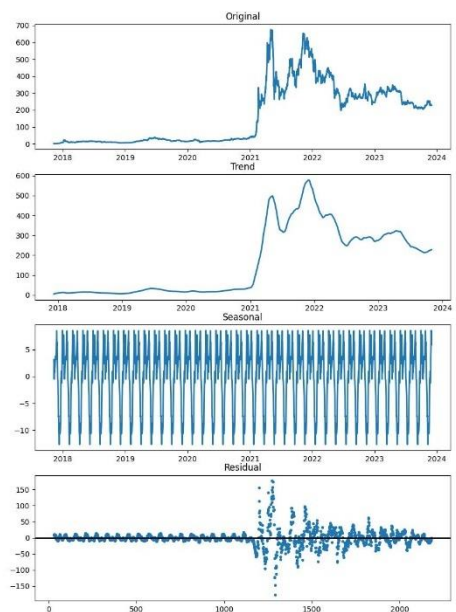
以太幣全部區間相加模型(period=60)

以太幣全部區間相乘模型(period=60)





以太幣小時區間相加模型(period=12)

以太幣小時區間相乘模型(period=12)




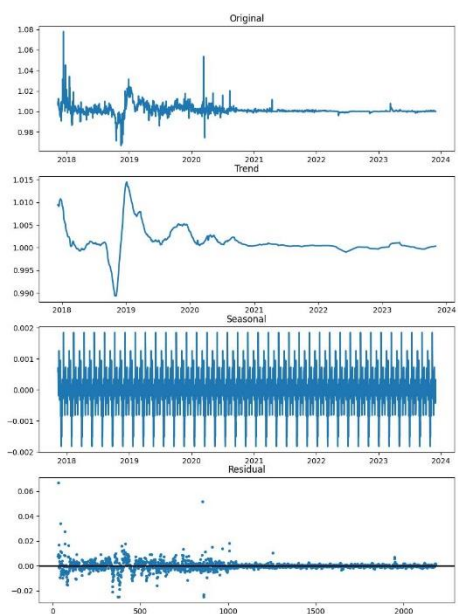
幣安幣全部區間相加模型(period=60)

幣安幣全部區間相乘模型(period=60)




幣安幣小時區間相加模型(period=12)

幣安幣小時區間相乘模型(period=12)

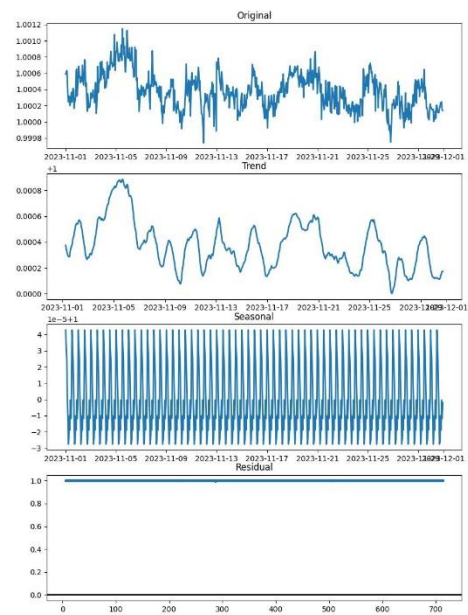


泰達幣全部區間相加模型(period=60)

泰達幣全部區間相乘模型(period=60)



泰達幣小時區間相加模型(period=12)



泰達幣小時區間相加模型(period=12)